

# Динамические методы ансамблирования необходимы там, где статичные модели теряют

Актуальность и проблема исследования

## Проблема данных

HFT-горизонты характеризуются преобладанием микроструктурного шума (спред, спонтанные удары) над полезным сигналом.

## Проблема модели

Классические ML-модели быстро деградируют из-за сдвига рыночных режимов (Concept Drift) и нестационарности рядов.

## Идея решения

Обучить гетерогенный ансамбль с динамическим механизмом внимания (Attention) и прямой оптимизацией по финансовому результату.

## Проблема оптимизации

Стандартные метрики (MSE, Accuracy) не учитывают ширину спреда и торговые издержки, приводя к убыточным торговым сигналам.

Практический смысл: Разработанный программный комплекс на Python/PyTorch имеет латентность инференса 2–5 мс, что позволяет интегрировать его в реальный торговый контур MOEX через протоколы FAST/FIX.

# Цель работы — разработать и экспериментально проверить адаптивную ансамблевую модель для высокочастотного трейдинга.

Цель, объект, предмет и задачи

**Разработать и экспериментально проверить методику построения гетерогенного динамического ансамбля с механизмом внимания для краткосрочного прогнозирования цен на высокочастотных данных Московской биржи.**

## Объект исследования

Процесс краткосрочного прогнозирования цен на финансовых рынках.

## Предмет исследования

Коллективные методы (ансамбли) машинного обучения.

## Задачи, вынесенные в презентацию

1. Свести событийный поток к дискретизированным признакам ( $S(t)$ ).
2. Спроектировать архитектуру ансамбля на базе CatBoost, KAN и Mamba.
3. Разработать экономически-ориентированную функцию потерь (PDL).
4. Проверить качество прогнозов на OOS-выборке через очищенную кросс-валидацию.

# Эмпирическая база и метод разметки данных

Исходный поток сделок агрегируется по фиксированным 5-секундным интервалам. Для каждого интервала строится токен:


## Параметры набора данных

Инструмент: Фьючерс на пару USD/RUB (Si), Московская биржа.  
Период и объем: Май 2025 — Апр 2026 (> 220 000 минутных баров).  
Препроцессинг: Применено событийно-управляемое сэмплирование (удаление периодов рыночного «флэта» для фокуса на ценовых импульсах).

## Разметка целевой переменной (Метод тройного барьера)


Для формирования сигналов классификации использованы динамические барьеры, зависящие от текущей волатильности:

- Take Profit (1): Верхний барьер. Сделка закрыта с прибылью.
- Stop Loss (0): Нижний барьер. Убыток ограничен.
- Time Horizon (NaN): Вертикальный барьер. Если цена не достигла уровней за 10 минут, сигнал отбрасывается как неинформативный.



# Архитектура Adaptive Attention Meta-Learner

Вместо статичного усреднения (Voting) реализована динамическая маршрутизация.



Архитектура Adaptive Attention Meta-Learner

## Разметка целевой переменной (Метод тройного барьера)

- Вектор состояния рынка  $S(t)$ : Включает микроструктурные признаки — дисбаланс стакана (OBI), ширину спреда и волатильность.
- Базовые модели (Гетерогенность):
  - CatBoost: Робастный фильтр выбросов и шума.
  - KAN-proxy: Извлечение сложных коинтеграционных нелинейностей.
  - Mamba-SSM: Захват долгосрочного контекста с линейной сложностью  $O(N)$ .
- Механизм внимания: MLP-модуль анализирует  $S(t)$  и через Softmax с температурой  $\tau$  назначает веса каждой модели в моменте.

Цель разработки архитектуры: Создать систему, способную в реальном времени адаптироваться к смене рыночных режимов, нивелируя микроструктурный шум за счет динамического перераспределения весов между моделями разной математической природы.


# Динамика обучения и кросс-валидация (CPCV)

## Процесс оптимизации (Левый график)

- Целевая функция: Profit-Driven Loss (PDL).
- Сходимость: Модель достигает стабильного плато к 50-й эпохе.
- Стабильность: Отсутствие роста валидационного убытка подтверждает устойчивость нейросети к микроструктурным изменениям в рамках выбранного окна обучения.

## Результаты кросс-валидации (Правый график)

- Метод: Combinatorial Purged Cross-Validation (5 фолдов).
- Метрика: ROC-AUC.
- Среднее значение: 0.9071 (разброс pm 0.0015).
- Вывод: Стабильность метрик на всех пяти фолдах доказывает, что алгоритм успешно извлекает инвариантные закономерности и не подвержен переобучению на конкретных участках временного ряда.



# Combinatorial Purged Cross-Validation (CPCV)

## Проблема стандартной валидации:


Временные ряды автокоррелированы. Использование обычного K-Fold ведет к утечке данных (Data Leakage).

## Очищенная кросс-валидация:

- Purge (Очистка): Удаление 15 минут данных перед началом тестового фолда.
- Embargo (Эмбарго): Изоляция 10 минут данных после окончания тестового фолда.


## Результат

Защита от переобучения. На 5 изолированных фолдах средний ROC-AUC составил 0.9071.



Матрица ошибок, Аккураси ~54% — это норма для рынка, так как модель максимизирует PnL, а не Аккураси

# Финансовые метрики и кривая капитала (Out-of-Sample)



| Метрика (с учетом комиссии 1 б.п.)             | Attention Ensemble | CatBoost   | Buy & Hold |
|------------------------------------------------|--------------------|------------|------------|
| <b>Sharpe Ratio</b><br>(доходность / риск)     | <b>4.14</b>        | 3.23       | -1.80      |
| <b>Sortino Ratio</b><br>(защита от спада)      | <b>6.21</b>        | 4.87       | -2.10      |
| <b>Calmar Ratio</b><br>(доходность / просадка) | <b>3.82</b>        | 2.64       | -0.90      |
| <b>Expected Shortfall (CVaR 95%)</b>           | <b>-0.43 б.п.</b>  | -0.61 б.п. | —          |
| <b>Max Drawdown</b><br>(Макс. просадка)        | <b>-5.2%</b>       | -8.4%      | -24.1%     |
| <b>Profit Factor</b>                           | <b>1.87</b>        | 1.54       | —          |

## Результат

**Асимметрия потерь:**  
Коэффициент Сортино (6.21) и тонкий хвост риска (CVaR 95% = -0.43 б.п.) доказывают, что оптимизация через функцию PDL успешно блокирует ложные входы при расширении спреда. Стратегия полностью готова к интеграции в реальный контур риск-менеджмента HFT-фонда.

# Итоги работы

1

Подготовлен HFT-корпус данных с микроструктурными признаками и Triple-Barrier разметкой.

2

Реализована архитектура Attention Meta-Learner с энтропийной регуляризацией и функцией PDL.

3

Доказано эмпирическое превосходство динамического ансамбля над статическими алгоритмами на OOS-выборке.

**Вывод: поставленная цель достигнута — разработанный адаптивный ансамбль превосходит классические методы по риск-метрикам и готов к интеграции в реальный торговый контур (latency 2–5 мс).**

**Спасибо за внимание!**



ФИНАНСОВЫЙ  
УНИВЕРСИТЕТ  
ПРИ ПРАВИТЕЛЬСТВЕ РОССИЙСКОЙ ФЕДЕРАЦИИ