

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	2
Глава 1. Теоретические основы краткосрочного прогнозирования на финансовых рынках.....	6
1.1 Особенности биржевых данных: структура, шумность, высокочастотность, проблема спонтанных колебаний цен.	6
1.2 Современные методы интеллектуального анализа данных (Data Mining, ML) в финансовой сфере.	13
Глава 2. Коллективные методы интеллектуальной обработки данных	23
2.1 Классификация ансамблевых методов: bagging, boosting, stacking, voting-комбинации.....	23
2.2 Архитектура мета-модели на базе механизмов внимания (Attention Meta-Learner)	32
2.3 Формализация целевой асимметричной метрики Profit-Driven Loss (PDL) ...	39
2.4 Формирование эмпирической базы и конструирование микроструктурных признаков.....	41
2.5 Программная реализация алгоритма и дизайн вычислительного эксперимента	44
Глава 3. Разработка и исследование ансамблевой модели для краткосрочного прогнозирования цен.....	48
3.1 Описание исходных данных: выбор финансовых инструментов, источники, период и частота данных.....	48
3.2 Оптимизация и обучение мета-алгоритма	52
3.3 Анализ результатов, выводы о перспективности ансамблей.....	55
ЗАКЛЮЧЕНИЕ	67
ПРИЛОЖЕНИЯ.....	78

ВВЕДЕНИЕ

Глобальные финансовые рынки сегодня отличаются исключительной волатильностью и многоуровневой микроструктурной организацией. На фоне того, что алгоритмические торговые системы формируют свыше 80% совокупного оборота биржевых площадок, традиционные эконометрические инструменты и отдельно взятые алгоритмы машинного обучения неизбежно теряют свою предиктивную силу — явление, известное как сдвиг концепта (concept drift). Решение задачи точного краткосрочного прогноза ценовой динамики активов предполагает разработку адаптивных гибридных систем, способных синтезировать разнородные рыночные сигналы в условиях предельно зашумлённых высокочастотных потоков биржевых данных (High-Frequency Data, HFD).

Злободневность выбранной темы определяется совокупностью трёх фундаментальных факторов, характеризующих состояние рынков в 2026 году. Первое — стремительное развитие предобученных фундаментальных моделей для временных рядов (Time-Series Foundation Models — TimesFM, Chronos) и архитектур на пространствах состояний (State-Space Models, в частности Mamba) сформировало новую планку качества при анализе последовательных данных. Вместе с тем непосредственное применение этих архитектур к «сырым» биржевым котировкам нередко оборачивается переобучением на микроструктурном шуме. Второе — классические ансамблевые техники (бэггинг, бустинг) исчерпывают свои возможности при анализе нестационарных рыночных режимов. Возникает острая необходимость в гибридных коллективных подходах — прежде всего в динамическом стэкинге (Dynamic Stacking), при котором веса составляющих моделей корректируются в режиме реального времени посредством механизма внимания (Attention). Третье — в отечественной алгоритмической торговле на площадке Московской биржи (MOEX) по-прежнему не решена проблема несоответствия между статистическими показателями точности моделей (MSE, MAE) и их реальной

финансовой результативностью (PnL) с учётом переменного спреда и транзакционных издержек.

Цель настоящей выпускной квалификационной работы состоит в проектировании, теоретическом исследовании и практической программной реализации адаптивного ансамблевого метода интеллектуальной обработки высокочастотных биржевых потоков данных, направленного на повышение точности и экономической рентабельности краткосрочных прогнозов ценовых изменений.

Для реализации поставленной цели в работе сформулированы следующие исследовательские задачи:

1. Исследовать эволюционный путь методов машинного обучения в области прогнозирования временных рядов, определив границы применимости современных архитектур (Transformers, SSM) при работе со скачкообразными изменениями цен и кластеризацией волатильности;
2. Спроектировать архитектуру адаптивного динамического ансамбля (Adaptive Attention-based Ensemble), объединяющего градиентный бустинг на деревьях решений, сети Колмогорова–Арнольда (KAN) и предварительно обученные Foundation-модели;
3. Разработать и формализовать специализированную функцию потерь (Profit-Driven Loss), непосредственно пенализирующую ансамбль за экономически убыточные торговые сигналы с учётом микроструктурных особенностей МОЕХ;
4. Провести полномасштабный вычислительный эксперимент на актуальных исторических данных МОЕХ за период высокой волатильности 2026 года с применением векторизованного бэктестинга;
5. Провести оценку экономической состоятельности разработанного ансамблевого алгоритма через призму риск-скорректированных показателей эффективности (Sortino Ratio, Calmar Ratio) и выработать

практические рекомендации по его встраиванию в контур HFT-систем.

Объектом исследования служат массивы высокочастотных биржевых данных Московской биржи — минутные агрегации котировок финансовых инструментов.

Предметом исследования выступают коллективные методы и алгоритмические решения машинного обучения, применяемые для краткосрочного предсказания направления и масштаба ценовых изменений торгуемых активов.

Методологическая база исследования включает аппарат теории вероятностей, математической статистики, методы машинного обучения и глубоких нейронных сетей (Gradient Boosting, KAN, State-Space Models, механизм Attention). Весь программный комплекс реализован на языке Python с использованием фреймворков PyTorch, CatBoost, Optuna и специализированной библиотеки векторизованного бэктестинга VectorBT.

Научная новизна настоящей работы определяется рядом оригинальных авторских решений:

1. Предложена и реализована архитектура гетерогенного адаптивного ансамбля, в котором мета-модель на основе механизма внимания (Attention Meta-Learner) в реальном времени перераспределяет доверительные веса между базовыми предикторами (CatBoost, KAN, Mamba) в соответствии с текущим режимом волатильности, идентифицируемым через скрытые марковские модели.
2. Разработана оригинальная асимметричная функция потерь (Profit-Driven Loss), обеспечивающая асимметричную оценку прогнозных ошибок: функция целенаправленно подавляет ложноположительные торговые сигналы в моменты расширения bid-ask спреда — критический аспект, игнорируемый стандартными метриками типа MSE.

Практическая ценность работы определяется созданием готового к внедрению прогнозного пайплайна, интегрируемого в торговую инфраструктуру

инвестиционных фондов и проп-трейдинговых компаний. Разработанная система демонстрирует стабильно более высокий коэффициент Шарпа по сравнению с лучшими изолированными SOTA-моделями на задачах внутридневного трейдинга.

Глава 1. Теоретические основы краткосрочного прогнозирования на финансовых рынках

Проблема краткосрочного прогнозирования на финансовых рынках входит в число наиболее трудоёмких задач интеллектуального анализа данных. Её сложность определяется уникальными свойствами биржевой информации и нетривиальной динамикой ценообразования в условиях высокой рыночной неопределённости. Настоящая глава посвящена систематическому изложению теоретических основ прогнозирования: анализу структуры и ключевых статистических свойств биржевых временных рядов, а также обзору актуальных методологических подходов, базирующихся на технологиях машинного обучения и интеллектуального анализа данных.

1.1 Особенности биржевых данных: структура, шумность, высокочастотность, проблема спонтанных колебаний цен.

Структура биржевых данных

Биржевые данные формируются в результате непрерывного процесса сделок на организованных торговых площадках (exchanges) и представляют собой последовательность событий, включающих цены исполненных сделок (trades), котировки заявок на покупку и продажу (bid/ask quotes), объёмы торгов (volumes) и другие параметры, характеризующие состояние рынка. Основными типами биржевых данных являются:

- Тиковые данные (tick data) — фиксация каждой отдельной сделки или изменения котировок в реальном времени без агрегации, что создаёт нерегулярно расположенные во времени наблюдения.
- Высокочастотные данные (high-frequency data, HFD) — агрегированные временные ряды с частотой от миллисекунд до минут (1-секундные, 1-минутные бары), используемые для алгоритмической торговли.
- Низкочастотные данные (daily/weekly data) — традиционные временные ряды с дневной или недельной дискретизацией, применяемые для среднесрочного анализа и фундаментальных моделей.

Каждое наблюдение в высокочастотных данных содержит четыре ключевых параметра: цену открытия (Open), максимум (High), минимум (Low) и

цену закрытия (Close), а также объём торгов — так называемая OHLCV-структура. Дополнительно могут включаться биржевой стакан (order book), агрессивность ордеров и метки направления сделки (buy/sell-initiated).

Шумность и микроструктура рынка

Ключевой особенностью биржевых данных, отличающей их от других типов временных рядов, является наличие микроструктурного шума (market microstructure noise). Этот шум порождается следующими факторами:

- 1 Bid-ask spread — разница между лучшей ценой покупки и продажи, приводящая к систематическим отклонениям наблюдаемых цен от теоретической «эффективной цены» (efficient price). Эмпирические исследования показывают, что подписанный спред (signed spread), умноженный на направление сделки, объясняет до 70% дисперсии микроструктурного шума.
- 2 Дискретность котировок — цены изменяются дискретными шагами (tick size), что особенно заметно для низколиквидных инструментов и приводит к искусственной кластеризации цен на уровнях тика. Отношение тика к спреду (tick-to-spread ratio) является ключевым предиктором уровня шума.
- 3 Bid-ask bounce — чередование сделок по цене bid и ask, создающее высокочастотную осцилляцию наблюдаемых цен вокруг истинной стоимости актива.
- 4 Информационная асимметрия и стратегическое поведение — институциональные игроки намеренно дробят крупные позиции на серию мелких ордеров, снижая тем самым рыночное воздействие; это индуцирует устойчивую автокорреляцию в потоке заявок и запаздывающую реакцию котировок.

В финансовой эконометрике феномен микроструктурного шума формализуется через декомпозицию наблюдаемой цены на аддитивные компоненты:

$$P_t = P_t^* + \epsilon_t$$

Где P_t — наблюдаемая цена финансового актива на бирже в момент времени, P_t^* — истинная (латентная, скрытая от прямого наблюдения) эффективная цена актива, отражающая фундаментальный рыночный консенсус; ϵ_t — компонента микроструктурного шума, которая в общем случае обладает свойствами автокорреляции. Ключевая проблема заключается в том, что по мере перехода исследователя к все более высоким частотам наблюдений, дисперсия шумовой компоненты начинает экспоненциально расти и многократно превышать дисперсию истинного ценового сигнала. Это делает стандартные эконометрические метрики волатильности крайне смещёнными.

Высокочастотность и стилизованные факты

Высокочастотные биржевые ряды демонстрируют устойчивый набор эмпирических закономерностей, получивших в научной литературе название стилизованных фактов (stylized facts). Их воспроизводимость на различных классах активов и временных горизонтах свидетельствует об универсальном характере рыночной микродинамики. К числу ключевых стилизованных фактов относятся:

- Нестационарность — ценовые ряды P_t обычно нестационарны (имеют единичный корень), тогда как логарифмические доходности $r_t = \log\left(\frac{P_t}{P_{t-1}}\right)$ слабо стационарны.
- Отсутствие автокорреляции в доходностях — доходности часто ведут себя как белый шум, $\text{Corr}(r_t, r_{t-k}) \approx 0$, то согласуется с гипотезой эффективного рынка.
- Кластеризация волатильности (volatility clustering) — периоды высокой изменчивости цен сменяются периодами низкой волатильности, что проявляется в автокорреляции квадратов доходностей: $\text{Corr}(r_t^2, r_{t-k}^2) > 0$. Мандельброт (1963) описал это явление как “большие изменения следуют за большими, малые — за малыми”.
- Тяжёлые хвосты и эксцесс — распределение доходностей имеет более толстые хвосты, чем нормальное (leptokurtosis), с эксцессом $k > 3$, что

увеличивает частоту экстремальных событий.

- Агрегационная гауссовость — с ростом временного горизонта агрегации (от минут к дням и неделям) распределение доходностей постепенно приближается к нормальному, что согласуется с центральной предельной теоремой.

Совокупность перечисленных свойств делает необходимым применение специализированного инструментария, прежде всего моделей условной гетероскедастичности класса ARCH/GARCH и нелинейных алгоритмов машинного обучения.

Для строгой проверки перечисленных стилизованных фактов в настоящем исследовании применяется двусторонний тест Дики–Фуллера (Augmented Dickey–Fuller, ADF). Нулевая гипотеза H_0 теста утверждает наличие единичного корня (нестационарности) в исследуемом ряду. Результаты ADF-теста на логарифмических доходностях фьючерса Si, полученные в ходе вычислительного эксперимента, показали значение тест-статистики $-142,41$ при $p\text{-value} < 10^{(-106)}$, что категорически отвергает гипотезу о единичном корне. Тем самым эмпирически подтверждается слабая стационарность ряда лог-доходностей — необходимое условие корректного применения алгоритмов машинного обучения.

Параллельно применялся тест Жака–Бера (Jarque–Bera test) для оценки отклонения эмпирического распределения от нормального. Полученные результаты (JB-статистика = $4,83 \times 10^9$, $p\text{-value} \approx 0$) однозначно свидетельствуют о наличии выраженного лептокуртоза (эксцесс Kurt = $2\,579,92$) и правосторонней асимметрии (Skew = $21,38$). Подобные значения эксцесса принципиально несовместимы с допущением гауссовости распределения, являющимся базовым в классической эконометрике, что дополнительно мотивирует применение нелинейных ансамблевых архитектур.

Спектральный анализ и долгосрочная память рядов доходностей

Помимо стандартных стилизованных фактов, высокочастотные финансовые ряды характеризуются явлением долгосрочной памяти (long-range

dependence), формально описываемым через дробно-интегрированные процессы (ARFIMA). В ряде академических работ (Cont, 2001; Bouchaud et al., 2018) было показано, что квадраты логарифмических доходностей обнаруживают гиперболически затухающую автокорреляционную функцию (ACF), хвост которой убывает как $1-\alpha$, где $\alpha \in (0, 1)$. Данный факт свидетельствует о том, что кластеризация волатильности не является кратковременным явлением: шоки волатильности могут сохранять статистическое влияние на горизонтах в сотни и тысячи баров.

В рамках проведённого эмпирического анализа функция ACF квадратов доходностей фьючерса S_t демонстрирует устойчивую положительную автокорреляцию на всех исследованных лагах (от 1 до 40 минут), что эмпирически подтверждает как ARCH-эффект, так и наличие длинной памяти в волатильности. Данное свойство является принципиальным обоснованием включения реализованной волатильности нескольких горизонтов (RV_{5m} , RV_{15m} , RV_{60m}) в вектор состояния рынка $S(t)$, используемый механизмом внимания.

Влияние внутридневной сезонности на методологию прогнозирования

Особой характеристикой высокочастотных биржевых данных, принципиально важной для корректной постановки задачи прогнозирования, является выраженная внутридневная сезонность (intraday seasonality) ключевых рыночных метрик. Данное явление проявляется в детерминированном изменении среднего уровня волатильности, ликвидности и ширины спреда в зависимости от астрономического времени торговой сессии. На Московской бирже наблюдается характерный U-образный профиль активности: пик ликвидности и волатильности приходится на первые 60–90 минут торговой сессии (09:00–10:30 МСК, открытие) и предпоследний час перед закрытием вечерней сессии.

Игнорирование данной сезонности при формировании обучающей выборки приводит к систематическому смещению (bias) в оценках модели: алгоритм, обученный на данных периодов высокой волатильности, будет

генерировать избыточные торговые сигналы в спокойные часы дня. Для устранения этого эффекта в разработанном программном комплексе применяется два инструмента. Во-первых, скользящая нормализация (Rolling Z-Score) признаков на окне, внутри которого сезонная составляющая считается константной. Во-вторых, добавление в вектор признаков номера часа торговой сессии (Session_Hour) в качестве явного регуляризатора, позволяющего модели обусловиться на временной контекст.

Визуальное подтверждение данной закономерности представлено на рисунке 3.1 (блок «Внутридневная сезонность волатильности по часам торговой сессии»): средняя реализованная волатильность RV в часы 10–12 достигает значений в 2,5–3 раза выше, чем в середине сессии. Именно поэтому признак Session_Hour занимает второе место по значимости согласно SHAP-анализу ($SHAP \approx 0,053$), уступая только микроцене (Micro_Price).

Асимметрия рынка и левосторонний хвост распределения потерь

Отдельного рассмотрения заслуживает явление асимметрии (skewness) эмпирического распределения доходностей. В отличие от симметричной нормальной кривой, распределение доходностей большинства финансовых активов демонстрирует либо отрицательный (left skew), либо положительный (right skew) перекосяк. Отрицательная асимметрия означает, что крупные отрицательные возвраты («хвост потерь») встречаются существенно чаще, чем предсказывает нормальное распределение — феномен, напрямую связанный с психологией рыночной паники и эффектом принудительного закрытия позиций (margin calls).

Для фьючерса Si на исследуемом периоде 2025–2026 гг. зафиксирована выраженная положительная асимметрия ($Skew = 21,38$), что нетипично для большинства фондовых инструментов. Данное значение обусловлено рядом резких девальвационных скачков рубля в исследуемом периоде, создавших экстремальные правосторонние наблюдения. С точки зрения разработки алгоритмической стратегии это означает, что стандартный коэффициент Шарпа, предполагающий нормальность распределения доходностей, является неполной

характеристикой риска. Именно поэтому в дополнение к Sharpe Ratio в настоящей работе используются метрики Sortino Ratio (учитывает только нисходящую дисперсию) и Calmar Ratio (учитывает максимальную просадку), которые дают более адекватную оценку качества стратегии в условиях асимметрии.

Проблема спонтанных колебаний цен

Спонтанные (резкие, аномальные) колебания цен — jumps — представляют собой дискретные скачки, не объясняемые непрерывной диффузионной составляющей процесса ценообразования. Такие скачки возникают при выходе неожиданных новостей (earnings announcements, макроэкономические релизы), техногенных сбоях (flash crashes) или манипуляциях рынком. Наличие скачков осложняет идентификацию истинной волатильности и требует отдельной декомпозиции вариации цены на непрерывную и дискретную компоненты, что реализуется, например, в методах realized kernel или bi-power variation.

При построении краткосрочных прогнозов принципиально разграничивать два качественно разных типа ценовой изменчивости:

- Систематическая волатильность — предсказуемая компонента, моделируемая GARCH, стохастической волатильностью или ML-моделями.
- Аномальные скачки — непредсказуемые события, которые можно лишь попытаться детектировать post-factum или включать в модели через extreme value theory.

В таблице 1 систематизированы ключевые характеристики биржевых данных различной частотности и их влияние на выбор методов анализа.

Таблицы 1. Сравнение характеристик низко- и высокочастотных биржевых данных

Характеристика	Низкочастотные данные (daily)	Высокочастотные данные (intraday)
Частота наблюдений	1 раз в день	Секунды–минуты
Микроструктурный шум	Незначителен	Доминирует
Волатильность кластеризация	Умеренная	Ярко выражена
Скачки цен	Редки	Частые из-за HFT
Стационарность доходностей	Условно стационарны	Нестационарны внутри дня
Применимость ARIMA	Высокая	Низкая из-за шума

Источник: составлена автором

1.2 Современные методы интеллектуального анализа данных (Data Mining, ML) в финансовой сфере.

Интеллектуальный анализ данных (Data Mining) и машинное обучение (Machine Learning) охватывают широкий спектр вычислительных методов, позволяющих автоматически выявлять закономерности в массивах данных без явного задания правил. В финансовой сфере данный инструментарий применяется для прогнозирования ценовой динамики, классификации рыночных состояний, кластеризации участников и обнаружения аномальных торговых паттернов. Принципиальное преимущество ML-подходов перед классической эконометрикой состоит в способности автоматически выстраивать сложные нелинейные зависимости и адаптироваться к структурным изменениям рыночной среды без ручной перекалибровки.

Классификация методов машинного обучения в финансовом прогнозировании

Применительно к задачам краткосрочного прогнозирования финансовых временных рядов методы машинного обучения целесообразно упорядочить по нескольким функциональным группам:

1. Данные модели традиционно выступают базовым эталоном при оценке прироста точности, обеспечиваемого более сложными подходами.

Базовые эконометрические бенчмарки (ARIMA, GARCH)

В историческом плане первыми строгими научными инструментами анализа финансовых временных рядов стали модели авторегрессии интегрированного скользящего среднего (ARIMA) и условной гетероскедастичности. В контексте высокочастотных рынков 2026 года эти линейные модели рассматриваются исключительно в качестве наивных бенчмарков (baseline models) для количественного обоснования преимуществ более современных ML-архитектур.

Математическая запись ARIMA(p,d,q) имеет вид:

$$\left(1 - \sum_{i=1}^p \varphi_i L^i\right) (1 - L)^d y_t = \left(1 + \sum_{j=1}^q \theta_j L^j\right) \epsilon_t$$

- где L – оператор лага, параметры AR и MA соответствуют авторегрессионной и скользящей компонентам.

Для моделирования условной волатильности и учета ее кластеризации применяется модель GARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

Эмпирические исследования показывают, что GARCH эффективен для дневных данных, но менее точен на высоких частотах из-за микроструктурного шума.

2. Классические модели машинного обучения (с учителем).

- Random Forest (RF) — ансамбль деревьев решений, обучаемых на

различных подвыборках данных (bagging) с случайным выбором признаков. Эмпирически RF демонстрирует высокую точность в финансовых задачах благодаря устойчивости к переобучению.

- Gradient Boosting Machines (XGBoost, LightGBM, CatBoost) — последовательные ансамбли деревьев, где каждое новое дерево минимизирует ошибку предыдущих. XGBoost и LightGBM особенно эффективны при работе с табличными данными и высокими размерностями признаков.

3. Глубокое обучение (Deep Learning)

- Глубокое нейросетевое обучение Recurrent Neural Networks (RNN, LSTM, GRU) — рекуррентные сети, исторически применявшиеся для моделирования последовательных зависимостей. Блок LSTM решает фундаментальную проблему затухания градиентов посредством системы вентилях (gates):

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

$$C_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot C_t$$

Где f_t, i_t — forget/input gates, C_t — cell state, h_t — hidden state.

Несмотря на популярность LSTM в прошлом, с 2024 года стандартом де-факто стали иные подходы. Опираясь на успех языковых моделей, были созданы базовые модели для временных рядов (Time-Series Foundation Models, такие как TimesFM от Google и Chronos). Данные архитектуры предварительно обучаются на триллионах точек рядов. Благодаря механизмам трансферного обучения они генерируют высокоточные прогнозы в режиме zero-shot (без дообучения на целевой выборке). Параллельно с ними широкое распространение получили архитектуры на базе пространств состояний (State-Space Models, SSM), в частности семейство Mamba. Они решили проблему квадратичной

вычислительной сложности Трансформеров, позволяя обрабатывать сверхдлинные высокочастотные последовательности котировок с линейной сложностью $O(N)$.

- Transformers и Attention механизмы — архитектуры, основанные на механизме внимания, позволяющие параллельно обрабатывать последовательности и фокусироваться на важных временных точках. Применяются в моделях типа Temporal Fusion Transformer для многогоризонтного прогнозирования.
- Convolutional Neural Networks (CNN) — свёрточные сети, адаптированные для временных рядов (1D-CNN), эффективно выделяющие локальные паттерны (например, "head-and-shoulders" в техническом анализе).

4. Гибридные и ансамблевые подходы

Комбинация различных моделей (ансамблирование) позволяет снизить дисперсию и смещение прогнозов. Основные техники:

- Bagging — параллельное обучение моделей на bootstrap-выборках с усреднением прогнозов (Random Forest — частный случай).
- Boosting — последовательное обучение с фокусом на ошибках предыдущих моделей (AdaBoost, XGBoost).
- Stacking — использование мета-модели для комбинации прогнозов базовых моделей. Например, предсказания LSTM, XGBoost и ARIMA подаются на вход линейной регрессии или градиентного бустинга для финального прогноза.

Сравнительный анализ эффективности ML-методов

Обобщение результатов эмпирических исследований показывает: единственно оптимального метода не существует. Рациональный выбор определяется свойствами конкретного временного ряда, горизонтом прогнозирования и используемыми критериями качества.

- Для внутридневных горизонтов (5–60 минут) архитектуры на основе

механизма внимания (Transformers, PatchTST) и сверточных временных сетей (TCN) демонстрируют статистически значимое преимущество перед рекуррентными моделями (RNN/LSTM) — за счёт отсутствия затухания градиента при обработке длинных последовательностей и принципиально лучшей параллелизации вычислений.

- Для дневного прогноза (1–10 дней): Random Forest и XGBoost стабильно превосходят линейные модели в метриках MAE/RMSE. Исследование на китайских акциях (2014–2022) показало, что Random Forest достигает наилучшего соотношения точности и низких ошибок I/II рода в задаче бинарной классификации направления.
- Ансамблевые методы демонстрируют наилучшие результаты в задачах финансовой дистресс-прогностики и предсказания волатильности, превосходя одиночные модели на 5–15% по ассурасу.

В таблице 2 приведена сравнительная характеристика методов по ключевым критериям качества.

Таблица 2. — Сравнение методов машинного обучения для краткосрочного прогнозирования

Метод	Интерпретируемость	Устойчивость к шуму	Вычислительная сложность	Точность на внутридневных данных
Random Forest	Средняя	Высокая	Средняя	Средняя

Метод	Интерпретируемость	Устойчивость к шуму	Вычислительная сложность	Точность на внутридневных данных
CatBoost / XGBoost	Высокая (через SHAP)	Высокая	Средняя	Высокая
LSTM / GRU	Низкая	Средняя	Высокая	Выше среднего
Transformers (PatchTS T)	Низкая	Высокая	Очень высокая	Очень высокая
Stacking (Ансамбль)	Низкая	Очень высокая	Высокая	Наивысшая

Источник: составлена автором

Проблемы и ограничения ML в финансовом прогнозировании

При всей результативности методов машинного обучения в финансовом прогнозировании необходимо учитывать их фундаментальные ограничения:

1. Переобучение (overfitting) — сложные модели (LSTM, глубокие сети) могут запоминать исторические паттерны, не обобщаемые на будущее, особенно при малых выборках. Регуляризация (dropout, L1/L2) и кросс-валидация на скользящем окне (walk-forward) критичны.

2. Нестационарность — структурные сдвиги в рыночной динамике (режимные переключения) приводят к деградации моделей, обученных на исторических данных. Требуются адаптивные схемы переобучения.
3. Интерпретируемость — регуляторы (Базель, MiFID II) требуют объяснимости моделей, что затруднено для глубоких сетей. Техники SHAP/LIME частично решают проблему.

Глубокое обучение для финансовых временных рядов: от LSTM к Foundation Models

Эволюция архитектур глубокого обучения в применении к финансовым временным рядам прошла несколько принципиально значимых этапов за последнее десятилетие. На протяжении 2015–2022 годов доминирующей парадигмой являлись рекуррентные сети (RNN) с ячейками долгой кратковременной памяти (Long Short-Term Memory, LSTM), предложенными Хохрайтером и Шмидхубером. Механизм вентилей (gates) в LSTM позволял сети избирательно «запоминать» информацию из отдалённых шагов последовательности, теоретически преодолевая проблему затухания градиентов в стандартных RNN. Однако практическое применение LSTM к высокочастотным биржевым данным неизменно выявляло фундаментальное ограничение: рекуррентная природа сети требует последовательной обработки токенов, исключая возможность параллелизации вычислений и принципиально ограничивая масштабируемость.

Переломным моментом в 2017–2018 годах стало появление архитектуры Transformer (Vaswani et al., «Attention is All You Need»), основанной исключительно на механизме самовнимания (Self-Attention). Ключевым преимуществом данной архитектуры является способность параллельно вычислять зависимости между произвольными позициями входной последовательности вне зависимости от их временной дистанции. Это позволяет модели одновременно «видеть» как ближайшие, так и отдалённые паттерны в ряду котировок. Адаптации архитектуры Transformer для временных рядов (Autoformer, Informer, PatchTST) демонстрируют значительное превосходство

над LSTM на внутридневных данных. Тем не менее квадратичная вычислительная сложность механизма внимания $O(N^2)$ остаётся препятствием при обработке сверхдлинных высокочастотных последовательностей ($>10\,000$ баров).

В 2023–2024 годах на передний план вышло семейство архитектур на основе пространств состояний (State-Space Models, SSM), наиболее известным представителем, которого является Mamba (Gu & Dao, 2023). Принципиальным отличием Mamba от Transformer является линейная сложность обработки $O(N)$ при сохранении способности к долгосрочному контекстному запоминанию. Модель реализует механизм селективного сканирования (Selective State Space), при котором параметры SSM являются функциями входных данных, что позволяет сети динамически фокусироваться на релевантных фрагментах последовательности, игнорируя шумовые участки — критически важное свойство для высокочастотных биржевых данных.

Сети Колмогорова–Арнольда (KAN) как альтернатива классическим MLP

Принципиально новым направлением в архитектурах нейронных сетей, появившимся в 2024 году, является KAN (Kolmogorov–Arnold Network), предложенная Лю и соавторами (Liu et al., «KAN: Kolmogorov–Arnold Networks», 2024). В основе KAN лежит теорема Колмогорова–Арнольда о суперпозиции, утверждающая, что любую непрерывную функцию нескольких переменных можно представить в виде суперпозиции конечного числа непрерывных функций одной переменной и операции сложения: $f(x_1, \dots, x_n) = \sum_i \Phi_i(\sum_j \varphi_{ij}(x_j))$.

В отличие от классических многослойных перцептронов (MLP), использующих фиксированные функции активации (ReLU, sigmoid) в узлах сети и обучаемые весовые коэффициенты на рёбрах, архитектура KAN размещает обучаемые одномерные функции-сплайны непосредственно на рёбрах (связях) между нейронами. Это обеспечивает два ключевых преимущества. Во-первых, существенно более высокую интерпретируемость: форма каждого сплайна

может быть визуализирована и понята как явная нелинейная зависимость между двумя признаками. Во-вторых, KAN теоретически требует значительно меньшего числа параметров для аппроксимации функций с нелинейной структурой по сравнению с MLP аналогичной глубины. В контексте финансового прогнозирования это позволяет KAN эффективно моделировать нелинейные взаимозависимости между микроструктурными признаками (например, нелинейное влияние дисбаланса OBI на краткосрочные доходности) без риска переобучения, присущего избыточно параметризованным MLP.

Transfer Learning и Foundation Models для финансовых временных рядов

Концепция предварительного обучения на огромных корпусах данных с последующей тонкой настройкой (Fine-Tuning) для конкретной задачи (Transfer Learning), принёсшая революционные результаты в обработке естественного языка (GPT, BERT) и компьютерном зрении, в 2023–2024 годах была успешно адаптирована для временных рядов. Модели TimesFM (Google DeepMind, 2024) и Chronos (Amazon, 2024) были обучены на петабайтах разнородных временных рядов (финансовые данные, метеорологические наблюдения, данные IoT-датчиков) и способны генерировать качественные прогнозы в режиме zero-shot — без какой-либо доработки на целевом наборе данных.

Применение Foundation Models к задачам прогнозирования биржевых инструментов, однако, сопряжено с рядом нетривиальных ограничений. Основное из них — явление «доменного разрыва» (domain shift): статистические свойства финансовых рядов (тяжёлые хвосты, нестационарность, микроструктурный шум) существенно отличаются от свойств большинства рядов из обучающего корпуса Foundation Model. Это означает, что применение TimesFM или Chronos к «сырым» тиковым данным нередко приводит к переобучению на доминирующем паттерне нормального распределения, присущем предобучающей выборке, и неудовлетворительным результатам на хвостовых событиях биржи. Именно поэтому в настоящей работе Foundation Models включены в гетерогенный ансамбль не напрямую, а через механизм

адаптивного взвешивания, который способен динамически снижать их долю в периоды микроструктурных шоков.

4. Эффект data snooping — многократное тестирование стратегий на одних и тех же данных завышает оценки эффективности. Необходимо строгое разделение train/validation/test с временным порядком.
5. Транзакционные издержки — высокая частота прогнозов может делать стратегии нерентабельными после учёта комиссий и проскальзывания. Оценка экономической значимости (Sharpe ratio, profit factor) важнее статистической.

Переход от статического к динамическому ансамблированию

В сложной высокочастотной среде классический статический стэкинг (Stacking) математически неэффективен. Если в процессе кросс-валидации градиентный бустинг получил статический вес 0.4, а нейронная сеть — 0.6, мета-модель будет слепо применять эти пропорции при любых рыночных условиях. Ответом на этот научный вызов стало динамическое ансамблирование (Dynamic Ensembling). В его математической основе лежит имплементация дифференцируемых механизмов внимания (Attention) на уровне мета-модели. Вектор состояния рынка (волатильность, ширина спреда) подается на вход управляющему блоку. Механизм внимания динамически, для каждого нового кванта времени, вычисляет уникальные вероятностные веса (Softmax) для каждой базовой модели в ансамбле. В условиях зашкаливающего высокочастотного шума ансамбль "штрафует" чувствительные генеративные модели и передает контроль робастному градиентному бустингу. При возвращении рынка в трендовую фазу веса возвращаются глубоким сетям. Именно математическая формализация архитектуры такого адаптивного динамического ансамбля является предметом исследований в Главе 2 настоящей работы.

Глава 2. Коллективные методы интеллектуальной обработки данных

Фундаментальный недостаток изолированных предиктивных моделей в алгоритмической торговле заключается в их жесткой привязке к определенным фазам рыночного цикла. В данной главе предлагается решение этой проблемы путем разработки архитектуры динамического гетерогенного ансамбля. Основная гипотеза исследования состоит в том, что введение дифференцируемого механизма внимания (Attention Meta-Learner) на метатренинге, а также использование кастомной асимметричной функции потерь, учитывающей микроструктурные издержки, позволит создать систему, устойчивую к концепт-дрифту (сдвигу концепта) высокочастотных данных Московской биржи.

2.1 Классификация ансамблевых методов: bagging, boosting, stacking, voting-комбинации.

Процесс комбинирования прогнозов нескольких моделей машинного обучения (ансамблирование) базируется на строгих математических принципах теории вероятностей и статистики. Главная цель создания коллективной модели в условиях финансового рынка — снижение дисперсии предсказательной ошибки (Variance Reduction) без существенного увеличения смещения (Bias). Для достижения этой цели в рамках данного исследования сформирован пул из трех архитектурно независимых предиктивных моделей, отвечающих технологическим стандартам 2026 года.

Метод бэггинга и случайный лес в задачах финансового прогнозирования

Метод бэггинга (Bootstrap Aggregating, Breiman, 1996) представляет собой технику параллельного ансамблирования, при которой N базовых моделей обучаются независимо на различных подвыборках исходного набора данных, сформированных методом bootstrap (с возвращением). Итоговый прогноз формируется как усреднение (для задач регрессии) или голосование по большинству (для задач классификации) выходов всех базовых моделей. Математически, если дисперсия каждого базового предиктора равна σ^2 , а корреляция между предикторами равна ρ , то дисперсия ансамбля из N моделей

составит: $\text{Var}(\text{ens}) = \rho\sigma^2 + ((1-\rho)/N)\sigma^2$. Из данного выражения следует принципиальный вывод: при стремлении N к бесконечности дисперсия ансамбля снижается до $\rho\sigma^2$, то есть ограничивается лишь взаимной корреляцией между базовыми предикторами. Это математически обосновывает необходимость максимальной гетерогенности моделей, входящих в ансамбль.

Случайный лес (Random Forest) является наиболее известной реализацией бэггинга, дополненной механизмом случайного выбора признаков на каждом узле дерева (Random Subspace Method). Данный механизм искусственно снижает корреляцию ρ между деревьями, что согласно приведённой формуле ведёт к дополнительному уменьшению дисперсии ансамбля. В контексте задачи настоящего исследования Random Forest рассматривается как значимый бенчмарк для оценки прироста, обеспечиваемого более сложными архитектурами (CatBoost, KAN, Mamba).

Бустинг: последовательная коррекция ошибок

Алгоритмы бустинга (Boosting), в отличие от бэггинга, строят ансамбль последовательно. Каждая новая базовая модель обучается не на исходных данных, а на «остатках» ошибок своих предшественников — так называемых псевдо-остатках (pseudo-residuals). В алгоритме AdaBoost (Freund & Schapire, 1995) данные наблюдения, на которых предыдущая модель ошиблась, получают повышенный вес в следующей итерации. Градиентный бустинг (Gradient Boosting Machines, Friedman, 2001) обобщил эту идею: каждое новое дерево минимизирует градиент произвольной дифференцируемой функции потерь $L(y, F(x))$. Математически, на k -й итерации дерево h_k обучается аппроксимировать отрицательный градиент функции потерь по текущим предсказаниям $F_{\{k-1\}}(x)$:

$$r_i = -\partial L(y_i, F(x_i)) / \partial F(x_i), \text{ при } F = F_{\{k-1\}},$$

где r_i — псевдо-остаток для i -го наблюдения; L — целевая функция потерь; $F_{\{k-1\}}(x)$ — текущий ансамблевый прогноз. Это обеспечивает возможность использовать произвольные (в том числе нестандартные, экономически мотивированные) функции потерь, что непосредственно эксплуатируется в разработанной функции Profit-Driven Loss.

Современные реализации градиентного бустинга — XGBoost (Chen & Guestrin, 2016), LightGBM (Ke et al., 2017) и CatBoost (Prokhorenkova et al., 2018) — значительно превосходят оригинальный GBM по вычислительной эффективности за счёт гистограммного приближения сплитов деревьев, GOSS-отбора наблюдений и специализированной обработки категориальных признаков. CatBoost, разработанный Яндексом, использует архитектуру «обливиусных» деревьев с симметричными разбиениями на каждом уровне, что обеспечивает конкурентоспособный инференс при минимальной вычислительной задержке — критически важное свойство для HFT-применений.

Стэкинг: иерархическая агрегация прогнозов

Алгоритм стэкинга (Stacked Generalization, Wolpert, 1992) реализует двухуровневую архитектуру ансамбля. На первом уровне (base level) несколько разнородных базовых моделей генерируют свои прогнозы на заданном наборе данных. На втором уровне (meta level) обучается мета-модель, которая принимает на вход прогнозы базовых моделей и синтезирует финальное предсказание. Ключевым требованием к корректной реализации стэкинга является использование техники кросс-валидации на этапе генерации обучающей выборки для мета-модели: базовые модели должны генерировать предсказания на данных, которые они «не видели» при обучении. В противном случае мета-модель выучивает артефакты переобучения базовых моделей, а не их реальные предсказательные паттерны.

Классический стэкинг с фиксированной мета-моделью (линейной регрессией, ридж-регрессией или логистической регрессией) присваивает базовым моделям статические веса, оптимальные в среднем на исторических данных. Фундаментальное ограничение данного подхода в контексте высокочастотного финансового прогнозирования состоит в том, что оптимальные веса базовых моделей существенно варьируются в зависимости от текущего рыночного режима. Это и обусловило необходимость перехода к динамическому ансамблированию через механизм внимания, детально описываемому в разделе 2.2.

Теорема Кондорсе и математические основания гетерогенности ансамбля

Ключевым теоретическим обоснованием принципа гетерогенного ансамблирования служит теорема Кондорсе о жюри (Condorcet's Jury Theorem, 1785), адаптированная к машинному обучению. В её основе лежит следующее утверждение: если каждый классификатор в ансамбле из N моделей принимает верное решение с вероятностью $p > 0,5$ независимо от остальных, то вероятность правильного решения большинства монотонно возрастает с ростом N и при $N \rightarrow \infty$ стремится к 1. Критическим условием является именно независимость ошибок (или, практически, минимальная корреляция ошибок) между базовыми моделями.

Математически, для ансамбля из трёх предикторов (как в настоящей работе — CatBoost, KAN, Mamba) вероятность ошибки большинства $P_{err} = 3p^2(1-p) + p^3$ и убывает по сравнению с вероятностью ошибки одиночного предиктора p^2 при $p > 0,5$. Выбор трёх архитектурно различных моделей — древовидной (CatBoost), сплайновой (KAN) и SSM-основанной (Mamba) — именно максимизирует структурную независимость ошибок, поскольку каждая модель склонна ошибаться на принципиально разных классах рыночных ситуаций.

Математические принципы гетерогенного ансамблирования и теорема Кондорсе

Эффективность коллективного прогнозирования математически обосновывается теоремой Кондорсе о жюри присяжных (Condorcet's jury theorem), адаптированной для задач машинного обучения. Согласно теореме, если вероятность правильного предсказания каждой индивидуальной базовой модели (base learner) $p > 0.5$, и при этом ошибки моделей являются статистически независимыми, то вероятность правильного решения ансамбля (при использовании мажоритарного голосования или взвешенного усреднения) стремится к единице при увеличении числа моделей N :

$$P(N) = 1 - \Phi \left(\frac{(0.5 - p) \sqrt{N}}{p \sqrt{1 - p}} \right) \quad (2.1)$$

где $P(N)$ — вероятность корректного предсказания ансамбля; Φ — функция стандартного нормального распределения; p — средняя предсказательная способность индивидуальной модели; N — количество базовых моделей в ансамбле.

Ключевым условием применимости данного закона является независимость (ортогональность) ошибок прогноза. В реальности алгоритмической торговли, если базовые модели имеют схожую архитектуру (например, только нейронные сети типа MLP), они склонны экстраполировать микроструктурный шум одинаково, их ошибки сильно коррелируют, и ансамблирование не приносит пользы.

Следовательно, для максимизации ортогональности предсказаний необходимо использовать алгоритмы с принципиально различным индуктивным смещением (inductive bias). Именно поэтому в архитектуру предложенного решения включены градиентный бустинг (деревья решений), сети KAN (сплайн-аппроксимация) и SSM-модели (марковские процессы).

Градиентный бустинг над небрежными деревьями (CatBoost) как робастный фильтр микроструктурного шума

В условиях высокочастотных финансовых данных, характеризующихся значительным уровнем гетероскедастичности и наличием сложных нелинейных зависимостей, алгоритмы градиентного бустинга над решающими деревьями (Gradient Boosting Decision Trees, GBDT) традиционно выступают в роли надежного предиктивного фундамента. В разрабатываемой архитектуре в качестве робастного "низкоуровневого" обработчика выбран алгоритм CatBoost.

Рисунок 2.1 — Архитектура симметричного (небрежного) решающего дерева в модели CatBoost




Рисунок 2.1 — Архитектура симметричного (небрежного) решающего дерева в модели CatBoost.

Математическая ценность данного алгоритма для гетерогенного ансамбля заключается в использовании так называемых "небрежных" или симметричных деревьев (oblivious trees). В отличие от классических бинарных решающих деревьев (применяемых, например, в алгоритме Random Forest или ранних версиях XGBoost), где предикаты (условия разбиения) в разных узлах одного уровня могут отличаться, симметричные деревья используют строго один и тот же предикат для всего уровня глубины.

Формально, прогнозируемое значение симметричного дерева с глубиной d для входного вектора x вычисляется по формуле:

$$F_{tree}(x) = \sum [I(x \in Leaf_j) * Val_j] \quad (2.2)$$

где I — индикаторная функция принадлежности вектора x к листу дерева j ;

Val_j — константное значение (прогноз) в листе j ;

Суммирование происходит по всем 2^d листьям дерева.

Использование единого предиката на уровень обеспечивает алгоритму высочайшую скорость инференса (за счет оптимизации кэша процессора и бинарных битовых масок), что критически важно для HFT-стратегий. Бустинг

демонстрирует непревзойденные результаты при работе со статичными снимками лимитной книги (L2 Order Book imbalances). В моменты экстремальных рыночных шоков (например, при явлениях Flash Crashes), когда сложные глубокие нейросети склонны к непредсказуемой и опасной экстраполяции, древовидные алгоритмы, чьи прогнозы ограничены значениями в листьях (*Val_j*), выступают главным стабилизирующим (консервативным) элементом ансамбля.

Архитектура нейронных сетей Колмогорова-Арнольда (KAN) в задачах аппроксимации финансовых рядов

Вторым компонентом ансамбля выступает инновационная архитектура KAN, пришедшая в 2024–2025 годах на смену классическим многослойным перцептронам (MLP). Фундаментальной математической базой классических MLP является теорема Цыбенко об универсальном аппроксиматоре. В свою очередь, сети KAN опираются на теорему Колмогорова-Арнольда о представлении непрерывных функций нескольких переменных в виде конечной суперпозиции непрерывных функций одной переменной и операции сложения.




Рисунок 2.2 — Сравнительная топология многослойного перцептрона (MLP) и сети Колмогорова-Арнольда (KAN).

В классических MLP обучаемыми параметрами являются скалярные линейные веса на ребрах графа вычислений, в то время как функции активации (например, ReLU, Sigmoid) жестко фиксированы в узлах (нейронах). В архитектуре KAN эта топологическая парадигма перевернута: узлы выполняют лишь примитивную функцию простого суммирования входящих сигналов, а обучаемые нелинейные функции расположены непосредственно на ребрах графа.

Каждая функция на ребре параметризуется с использованием одномерных В-сплайнов (B-splines). Выходной сигнал k -го узла в слое $l+1$ вычисляется как:

$$x^{(l+1)}_k = \sum_j [\Phi(j, k) (x^{(l)}_j)] \quad (2.3)$$

где $x^{(l)}_j$ — выходной сигнал j -го узла предыдущего слоя l ;
 $\Phi(j, k)$ — обучаемая одномерная нелинейная сплайн-функция на ребре, соединяющем узлы j и k .

Это математическое свойство позволяет сети KAN "выучивать" точные аналитические функции и инвариантные закономерности прямо из финансовых данных. Способность сетей Колмогорова-Арнольда выявлять тонкие коинтеграционные связи и сложные нелинейные парные корреляции между производными финансовыми инструментами (например, фьючерсом на индекс РТС и валютной парой USDRUB_TOM) делает их идеальным инструментом для поиска скрытого статистического арбитража. Кроме того, KAN обладает значительно меньшим количеством параметров по сравнению с MLP при аналогичной аппроксимирующей способности, что радикально снижает риск эффекта Data Snooping.

Модели пространств состояний (Mamba-TS) для извлечения долгосрочных контекстных зависимостей

Третьим, наиболее мощным генеративным компонентом ансамбля, выступают модели семейства Mamba, адаптированные для анализа временных рядов (Mamba-TS). Данная архитектура интегрирована в ансамбль для извлечения долгосрочных контекстных зависимостей и выявления макроскопических паттернов рыночного микроцикла.

Исторически стандартом для таких задач являлись Трансформеры (Transformers) с механизмом внутреннего внимания (Self-Attention). Однако механизм Self-Attention требует попарного вычисления скалярных произведений для всех токенов последовательности, что приводит к квадратичной вычислительной сложности от длины входного окна — $O(N^2)$. В реалиях алгоритмической торговли, где длина входного контекстного окна может достигать 100 000 миллисекундных тиков за торговую сессию, Трансформеры становятся вычислительно неприменимыми.

Архитектура Mamba изящно решает данную проблему за счет использования математического аппарата пространств состояний (State-Space Models, SSM), переведенного из непрерывного времени в дискретное. Непрерывная SSM описывает эволюцию скрытого состояния $h(t)$ и выходного сигнала $y(t)$ через систему дифференциальных уравнений:

$$h'(t) = A * h(t) + B * x(t) \quad y(t) = C * h(t) + D * x(t) \quad (2.4)$$

где $x(t)$ — входной биржевой сигнал (например, логарифмическая доходность); $h(t)$ — скрытое состояние модели; A, B, C, D — матрицы параметров системы.

Для применения к дискретным финансовым данным непрерывная система (2.4) подвергается дискретизации (например, методом Zero-Order Hold) с шагом Δ . Ключевой инновацией Mamba является алгоритм аппаратно-ориентированного селективного сканирования (Selective Scan). Матрицы B, C и параметр Δ становятся функциями от входного сигнала x_t , что позволяет модели "забывать" шумовые (бесполезные) тики и "запоминать" критически важные рыночные события.

В отличие от Трансформеров, рекуррентная природа дискретной модели Mamba позволяет обрабатывать тиковые последовательности феноменальной глубины с линейной асимптотической сложностью $O(N)$. Это устраняет проблему вычислительного "узкого горлышка" (bottleneck) при инференсе

алгоритма, давая предиктивной модели возможность "помнить" состояние рынка в момент открытия торговой сессии при принятии решений перед вечерним клирингом.

2.2 Архитектура мета-модели на базе механизмов внимания (Attention Meta-Learner)

Выбор мощных и гетерогенных базовых моделей является необходимым, но недостаточным условием для построения эффективной алгоритмической торговой системы. Ключевой научно-инженерной задачей выступает разработка математического аппарата, способного оптимально агрегировать предиктивные сигналы этих моделей в единый консенсус-прогноз. В данном разделе подробно описывается разработанная архитектура мета-модели на базе дифференцируемых механизмов внимания (Attention Gate), обеспечивающая динамическую маршрутизацию сигналов.

Концептуальные ограничения статического ансамблирования

В классической теории машинного обучения доминирующим методом комбинирования разнородных моделей выступает алгоритм стэкинга (Stacking), формализованный Д. Волпертом. При статическом стэкинге предполагается использование мета-модели второго уровня (чаще всего логистической или гребневой регрессии Ridge), которая обучается предсказывать итоговый результат на основе выходов базовых моделей (base learners), присваивая им фиксированные статические веса.

В сложной высокочастотной финансовой среде статический стэкинг математически и экономически неэффективен. Обусловленность этой неэффективности кроется в явлении сдвига концепта (Concept Drift) и наличии дискретных рыночных режимов. Если в процессе кросс-валидации на исторической выборке модель градиентного бустинга получила вес 0.4, а генеративная нейросеть — вес 0.6, классическая мета-модель будет слепо и неукоснительно применять эти весовые коэффициенты при любых будущих рыночных условиях.

Однако финансовые рынки перманентно переходят из состояния низкой энтропии (трендовый флэт) в состояние высокой энтропии (новостные шоки, кризисы ликвидности). Модель, идеально работающая в одном режиме, начинает генерировать катастрофические ошибки в другом. Таким образом, возникает фундаментальная потребность в переходе от статических весов к динамическим функциям времени, что реализуется через механизм внимания (Attention).

Формирование многомерного вектора состояния рынка

Для того чтобы мета-модель могла динамически перераспределять веса, она должна непрерывно получать информацию (контекст) о текущей микроструктурной фазе рынка. Качество работы механизма внимания напрямую зависит от информационной емкости вектора состояния рынка $S(t)$, вычисляемого синхронно с каждым новым тиком или баром. В рамках данного исследования вектор $S(t)$ конструируется на основе трех ортогональных метрик.

Во-первых, реализованная волатильность (Realized Volatility, RV) за скользящее окно M . Она характеризует текущий уровень ценовой турбулентности и вычисляется как квадратный корень из суммы квадратов внутридневных логарифмических доходностей:

$$RV(t, M) = \sqrt{(\sum_k [r_-(t - k)^2])} \quad (2.5)$$

где $RV(t, M)$ — реализованная волатильность в момент t за окно M ;

$r_-(t - k)$ — логарифмическая доходность на шаге $t - k$;

Суммирование происходит по k от 0 до $M - 1$.

Во-вторых, дисбаланс книги заявок (Order Book Imbalance, OBI). Данная метрика отражает текущее давление лимитных покупателей или продавцов на лучших уровнях биржевого стакана (Level 2):

$$OBI(t) = (V_{bid}(t) - V_{ask}(t)) / (V_{bid}(t) + V_{ask}(t)) \quad (2.6)$$

где $V_{bid}(t)$ — совокупный объем лимитных заявок на покупку на лучших ценовых уровнях;

$V_{ask}(t)$ — совокупный объем лимитных заявок на продажу.

Метрика $OBI(t)$ принимает значения в диапазоне $[-1; 1]$, где экстремальные значения сигнализируют о надвигающемся микроструктурном скачке цены.

В-третьих, в вектор состояния $S(t)$ включается скользящая нормированная ширина bid-ask спреда, характеризующая текущую стоимость ликвидности. Конкатенация данных признаков формирует плотный вектор $S(t)$, который служит "запросом" (Query) для механизма внимания.




Рисунок 2.3 — Процесс экстракции микроструктурных признаков и формирования вектора состояния рынка $S(t)$

Математический аппарат дифференцируемого механизма внимания

Механизм внимания мета-модели (Attention Gate) структурно представляет собой неглубокую полносвязную нейронную сеть (Multi-Layer Perceptron), архитектура которой вдохновлена механизмами Gating Network из парадигмы Mixture of Experts (MoE).

Блок внимания принимает на вход сформированный агрегированный вектор состояния $S(t)$, а также скрытые представления (hidden states) базовых моделей $h_i(t)$. Оценка релевантности (сырой логит) i -й базовой модели для конкретного текущего рыночного режима вычисляется по следующему уравнению:

$$score_i(t) = V^T * \tanh(W_s * S(t) + W_h * h_i(t) + b) \quad (2.7)$$

где $score_i(t)$ — скалярная оценка потенциальной компетентности i -й модели в момент t ;

V, W_s, W_h — параметрические обучаемые матрицы весов механизма внимания;

b — вектор смещения (bias);

$\tanh$ — гиперболический тангенс, выступающий нелинейной функцией активации.

Сырые оценки $score_i(t)$ не образуют корректного вероятностного распределения. Для их преобразования в итоговые весовые коэффициенты применяется модифицированная функция Softmax с гиперпараметром температуры (Temperature Scaling) τ :

$$w_i(t) = \exp(score_i(t) / \tau) / \sum \exp(score_j(t) / \tau) \quad (2.8)$$

где $w_i(t)$ — итоговый динамический вес i -й базовой модели;

τ (тау) — параметр температуры, определяющий "жесткость" маршрутизации; Суммирование в знаменателе происходит по всем базовым моделям ансамбля j .

Параметр температуры τ играет критическую роль в настройке ансамбля. При $\tau \rightarrow \infty$ распределение весов стремится к равномерному (эквивалент простого усреднения). При $\tau \rightarrow 0$ механизм внимания превращается в жесткий переключатель (Hard Routing), отдавая 100% веса одной наиболее "уверенной" модели (эквивалент argmax). В данной работе параметр τ оптимизируется в процессе обучения, позволяя сети самостоятельно находить баланс между мягким ансамблированием и жесткой селекцией.




Рисунок 2.4 — Архитектура адаптивного ансамбля Adaptive Attention Meta-Learner: входные данные OHLCV, базовые предикторы (CatBoost, KAN, Mamba) и механизм взвешивания $w_i(t)$

Экономическая интерпретация адаптивной маршрутизации

Итоговый консенсус-прогноз разрабатываемого гетерогенного ансамбля формируется как математическое ожидание индивидуальных прогнозов базовых моделей $Y_i(t)$ с учетом их вычисленной локальной компетентности:

$$Y_{ens}(t) = \sum w_i(t) * Y_i(t) \quad (2.9)$$

Адаптивная маршрутизация сигналов (Adaptive Routing), реализуемая через уравнения (2.7 - 2.9), обладает строгой экономической бизнес-логикой, необходимой для высокочастотного трейдинга. В процессе градиентного обучения на исторических биржевых паттернах мета-модель автоматически усваивает следующие паттерны поведения:

1. Режим высокой турбулентности (High Entropy State): Если информационный вектор $S(t)$ сигнализирует о резком расширении спреда, аномальном росте дисбаланса $OBI(t)$ и скачке волатильности (что типично для выхода новостей или Flash Crash), механизм внимания

алгоритмически "глушит" веса тяжеловесных глубоких нейросетей (Mamba, KAN). Эти сети обладают высокой емкостью и склонны переобучаться на хаотичном шуме, генерируя ложные сигналы. Управление динамически делегируется градиентному бустингу (CatBoost), чьи прогнозы структурно ограничены константами в листьях деревьев, что предотвращает катастрофическую экстраполяцию.

2. Режим трендового затишья (Low Volatility Regime): При сужении спреда и падении исторической волатильности (низкие значения RV), когда рынок формирует сложные нелинейные коинтеграционные паттерны, недоступные древовидным алгоритмам, механизм внимания плавно снижает вес бустинга и отдает приоритет архитектуре Mamba-TS. Модели на базе пространств состояний активируют свой долгосрочный контекст (long-term memory) и генерируют высокоточные сигналы на удержание среднесрочной позиции.

Таким образом, Attention Meta-Learner действует как интеллектуальный риск-менеджер в реальном времени, непрерывно оценивая не только математическую вероятность направления цены, но и степень микроструктурного доверия к каждому конкретному алгоритму ансамбля.

Математические свойства механизма температурного масштабирования

Параметр температуры τ в уравнении (2.8) выполняет роль регулятора «жёсткости» маршрутизации и оказывает принципиальное влияние на поведение ансамбля в различных рыночных условиях. При $\tau \rightarrow \infty$ функция softmax равномерно распределяет веса по всем базовым моделям ($w_i(t) = 1/N$ для всех i), что эквивалентно простому усреднению прогнозов. При $\tau \rightarrow 0$ распределение весов вырождается в унитарное: вся предсказательная сила концентрируется в модели с максимальным score (так называемый «жёсткий» переключатель, Hard Routing). Промежуточные значения $\tau \in (0, \infty)$ обеспечивают плавный переход между данными двумя крайними режимами.

В данной работе параметр τ рассматривается как обучаемый параметр нейронной сети (реализован через `nn.Parameter` в PyTorch). Оптимизация τ в процессе градиентного обучения позволяет мета-модели самостоятельно определить оптимальный баланс между диверсификацией (высокое τ , устойчивость к шуму) и специализацией (низкое τ , точность в определённых режимах). Диапазон допустимых значений τ ограничивается через `torch.clamp(self.temperature, min=0.1, max=5.0)` для предотвращения числовой нестабильности градиентов при крайних значениях.

Архитектурные особенности MLP Gate и инициализация весов

MLP Gate представляет собой трёхслойную полносвязную нейронную сеть с размерностью скрытого слоя 32. Для обеспечения стабильности обучения после первого линейного слоя применяется нормализация LayerNorm (Ba et al., 2016), которая нормирует активации по размерности скрытого слоя, устраняя проблему внутреннего ковариационного сдвига (internal covariate shift) без зависимости от размера батча — критически важное свойство при работе с небольшими батчами финансовых данных. Нелинейности реализованы через сочетание функций ReLU (первый скрытый слой) и Tanh (второй скрытый слой), что обеспечивает одновременно разреженность активаций (ReLU) и ограниченный выходной диапазон (Tanh) для повышения стабильности softmax.

Инициализация весов линейных слоёв производится методом Xavier Uniform (Glorot & Bengio, 2010), обеспечивающим дисперсию весов на уровне $\text{Var}(W) = 2/(n_{\text{in}} + n_{\text{out}})$, где n_{in} и n_{out} — размерности входного и выходного слоёв. Данная стратегия инициализации препятствует явлениям затухания и взрыва градиентов на начальных итерациях обучения, что особенно важно для механизмов внимания.

Интеграция LightGBM как четвёртого базового предиктора

Помимо трёх основных базовых предикторов (CatBoost, KAN-proxu, Mamba-proxu), в программной реализации ансамбля в качестве дополнительного предиктора используется LightGBM — альтернативная реализация градиентного бустинга с гистограммной аппроксимацией. Ключевое отличие LightGBM от

CatBoost — применение алгоритма GOSS (Gradient-based One-Side Sampling), исключающего из каждой итерации наблюдения с малыми градиентами и фокусирующегося на сложных случаях. Это обеспечивает более высокую скорость обучения на разреженных данных при сопоставимой точности.

На практике LightGBM и CatBoost демонстрируют различную чувствительность к гиперпараметрам и по-разному реагируют на изменение рыночных режимов, что повышает общую гетерогенность ансамбля. Прогнозы LightGBM (LGB_Prob) участвуют в формировании обучающей выборки для Attention Meta-Learner наравне с прогнозами остальных базовых моделей, однако не входят в итоговый консенсус-прогноз напрямую — их вклад опосредован через оптимизацию весов механизма внимания.

2.3 Формализация целевой асимметричной метрики Profit-Driven Loss (PDL)

Фундаментальной методологической проблемой академического машинного обучения применительно к финансовым рынкам является использование классических, симметричных метрик качества. Большинство глубоких нейронных сетей обучаются минимизировать среднеквадратическую ошибку (Mean Squared Error, MSE) или среднюю абсолютную ошибку (Mean Absolute Error, MAE). Данные функции симметричны: они в равной степени математически штрафуют оптимизируемую модель как за переоценку (overshooting), так и за недооценку (undershooting) будущего движения цены актива. Более того, эти метрики абсолютно "слепы" к микроструктуре рынка.

В условиях реальной алгоритмической торговли (особенно на HFT и MFT горизонтах) использование MSE ведет к катастрофическим просадкам депозита. Например, математическая ошибка прогноза модели в +0.02% при текущей ширине спреда брокера в 0.05% с точки зрения MSE выглядит как весьма точный предикт (низкое значение Loss). Однако на практике попытка алгоритма отторговать такой сигнал приведет к совершению гарантированно убыточной сделки, так как потенциальная прибыль будет полностью уничтожена пересечением bid-ask спреда и комиссией биржи (slippage).

Для обеспечения реальной экономической рентабельности разрабатываемого гетерогенного ансамбля, в процесс его градиентного обучения (алгоритм `backpropagation`) была внедрена кастомная, предметно-ориентированная функция потерь — Profit-Driven Loss (PDL). Данная дифференцируемая метрика напрямую аппроксимирует будущую кривую капитала (Equity Curve) торговой системы.




Рисунок 2.5 — Сравнительный профиль штрафов симметричной функции (MSE) и асимметричной функции Profit-Driven Loss (PDL)

Для интеграции экономической логики в граф вычислений нейросети необходимо, чтобы функция потерь оставалась дважды дифференцируемой. С этой целью бинарный дискретный торговый сигнал заменяется непрерывным. Сигнал на открытие позиции $Sig(t)$ формируется как плавная функция от итогового консенсус-прогноза ансамбля $Y_{ens}(t)$:

$$Sig(t) = \tanh(\alpha * Y_{ens}(t)) \quad (2.10)$$

где $Sig(t)$ — непрерывный псевдо-сигнал, принимающий значения в интервале $[-1; 1]$ (где значение -1 означает максимальную уверенность в падении актива и инициацию короткой позиции, 1 — инициацию длинной позиции, а значения близкие к 0 — нахождение вне рынка); α (альфа) — настраиваемый

гиперпараметр уверенности (Temperature Scaling), регулирующий агрессивность торговой логики и крутизну активации; $\tanh$ — гиперболический тангенс.

Фактический ожидаемый финансовый результат (Profit and Loss, PnL) на шаге t строго зависит от истинной реализации доходности инструмента $Y_true(t)$ в будущем и транзакционных издержек $C(t)$. Вектор издержек $C(t)$ не является константой; в него динамически закладывается половина ширины спреда в момент подачи заявки, маржинальные требования клирингового центра и фиксированные комиссии алгоритмического шлюза Московской биржи:

$$C(t) = 0.5 * Spread(t) + Comm \quad (2.11)$$

Целевая функция потерь PDL формулируется как отрицательное математическое ожидание реальной алгоритмической прибыли по всему обучающему батчу размером B :

$$L_PDL = - (1 / B) * \sum [Sig(t) * Y_true(t) - |Sig(t)| * C(t)] \quad (2.12)$$

где L_PDL — агрегированное значение функции потерь на батче, подлежащее минимизации градиентным спуском; $Y_true(t)$ — истинное изменение цены актива на заданном горизонте прогнозирования; Суммирование происходит по всем t от 1 до B .

Минимизация функции (2.12) заставляет мета-модель радикально менять свое предиктивное поведение. Ансамбль перестает получать градиентный штраф за "неточное" угадывание цены, если сделка в итоге приносит положительное математическое ожидание. И наоборот, модель получает колоссальный асимметричный штраф за генерацию торговых сигналов в условиях экстремально широкого спреда (когда ожидаемая амплитуда $|Y_true(t)| < C(t)$), даже если направление движения (знак прогноза) было угадано алгоритмом абсолютно верно.

2.4 Формирование эмпирической базы и конструирование микроструктурных признаков

Качество и репрезентативность обучающей выборки (Dataset) являются критическими факторами, определяющими итоговую успешность любой алгоритмической торговой стратегии. Обучение высокочастотных моделей на

низколиквидных активах или агрегированных дневных данных не позволяет раскрыть вычислительный потенциал нейросетевых архитектур. В связи с этим к процессу сбора и преобразования данных были применены строгие индустриальные стандарты квантитативного анализа.

Обоснование выбора финансовых инструментов. Для проведения эмпирического эксперимента были отобраны инструменты срочного рынка (рынка деривативов) Московской биржи (FORTS). Выбор обусловлен высокой ликвидностью, эффектом встроенного кредитного плеча и минимальными транзакционными издержками по сравнению со спотовым рынком. В качестве целевых инструментов были выбраны два фьючерсных контракта: фьючерс на курс доллара США к российскому рублю (тикер Si) и фьючерс на Индекс МосБиржи (тикер MXI). Инструмент Si исторически является самым ликвидным деривативом на MOEX, характеризующимся сильными микроструктурными трендами, тогда как MXI выступает бенчмарком широкого рынка.

Период исследования охватывает наиболее репрезентативный и волатильный интервал с начала января по конец апреля 2026 года. Данный период выбран намеренно, так как он включает принципиально различные режимы волатильности, что необходимо для корректного обучения механизма Attention Meta-Learner.

Инфраструктура сбора данных. Агрегированные дневные свечи обладают недостаточной информационной насыщенностью для задач внутридневного прогнозирования. Для реализации разработанной стратегии производился сбор минутных высокочастотных агрегаций (1-minute HFD). Выгрузка осуществлялась в автоматическом режиме через Информационно-статистический сервер Московской биржи (MOEX ISS API). Итоговый размер обработанного массива составил свыше 74 000 строк (баров), что представляет собой статистически значимую выборку, достаточную для сходимости внутридневных прогнозных моделей.

Конструирование признаков (Feature Engineering). Сырые биржевые данные содержат артефакты и пропущенные значения. На этапе предобработки

была применена линейная интерполяция и удаление неторговых периодов (клирингов). Признаковое пространство базовых моделей было расширено микроструктурными предикторами. Главным из них стала эффективная микроцена (Micro-Price) — взвешенная цена, учитывающая объемы лимитных заявок на лучших уровнях:

$$P_{micro}(t) = (P_{ask}(t) * V_{bid}(t) + P_{bid}(t) * V_{ask}(t)) / (V_{bid}(t) + V_{ask}(t)) \quad (2.13)$$

где $P_{micro}(t)$ — микроцена, более точно отражающая справедливую стоимость актива внутри спреда;

P_{ask} и P_{bid} — цены лучших заявок; V_{ask} и V_{bid} — объемы лучших заявок.

Для устранения нестационарности все входные признаки перед подачей в нейронные сети подвергались динамической нормализации на скользящем окне (Rolling Z-Score).

Таблица 3. Фрагмент структуры итогового обучающего набора данных

Временная метка (t)	Цена (Mid)	Спред (пт)	Волатильность (RV)	Дисбаланс (OBI)	Micro-Price
2026-02-10 10:05:10	92500	15	0.0012	0.45	92503.2
2026-02-10 10:05:20	92515	17	0.0015	0.68	92520.1
2026-02-10 10:05:30	92530	14	0.0018	0.12	92531.5

Разметка целевой переменной. Одним из распространённых методологических изъянов финансового прогнозирования является нацеленность алгоритма на предсказание цены в строго фиксированный момент будущего, что не отражает реальную логику исполнения торговых ордеров. В настоящей работе для формирования обучающего сигнала $Y_true(t)$, входящего в расчёт функции Profit-Driven Loss, применяется метод тройного барьера (Triple-Barrier Method).




Рисунок 2.6 — Визуализация разметки целевой переменной методом тройного барьера (Triple-Barrier Method): баланс классов, сигналы и динамический барьер

Вокруг цены в момент сигнала выстраиваются три барьера: целевая прибыль (Take Profit), ограничение убытка (Stop Loss) и вертикальный барьер максимального времени удержания позиции. Модель классифицирует, какой из барьеров будет пересечен первым. Это позволяет согласовать обучение с реальной механикой биржевого исполнения ордеров.

2.5 Программная реализация алгоритма и дизайн вычислительного эксперимента

Практическое воплощение разработанного математического аппарата потребовало применения современного набора программных инструментов.

Весь программный комплекс реализован на языке программирования Python версии 3.11.

Программный стек. Тензорные вычисления и построение дифференцируемых вычислительных графов (для сетей KAN, архитектуры Mamba и блока Attention Meta-Learner) реализованы на фреймворке PyTorch. Обучение и инференс градиентного бустинга выполнен средствами библиотеки CatBoost, специально оптимизированной для выполнения на графических процессорах (GPU).

Принципиальным архитектурным решением явился отказ от классического цикличного перебора (for-loop backtesting), производительность которого неприемлемо низка при работе с миллионами строк HFT-данных. Для симуляции торгового исполнения и расчёта PnL (Profit and Loss) задействован специализированный фреймворк VectorBT PRO, который векторизует все вычисления торговых сигналов с применением NumPy и компилятора Numba — это ускоряет перебор гиперпараметров ансамбля в тысячи раз по сравнению с итеративными решениями.

Комбинаторная очищенная кросс-валидация (CPCV). Использование ансамблевых моделей с многочисленными параметрами сопряжено с высоким риском переобучения и утечки данных (Data Leakage). Стандартная K-Fold кросс-валидация методологически несостоятельна применительно к временным рядам в силу их сильной сериальной автокорреляции: проникновение «будущих» наблюдений в обучающую выборку ведёт к тому, что модель де-факто «запоминает» предстоящую динамику, что порождает иллюзию высокой точности на исторических данных.

В целях предотвращения переобучения на исторических данных в настоящей работе реализован метод комбинаторной очищенной кросс-валидации (Combinatorial Purged Cross-Validation, CPCV), формализованный в работах М. Лопеса де Прадо. Метод предполагает введение двух временных карантинных буферов при формировании разбиений: зоны очистки (Purging) перед валидационным окном и зоны эмбарго (Embargo) после него.

Purged Cross-Validation (Time Series)




Рисунок 2.7 Архитектура очищенной кросс-валидации (CPCV) с карантинными временными буферами

Ширина карантинных зон задаётся равной максимальному горизонту удержания позиции. Это гарантирует, что мета-модель оптимизируется исключительно на статистически изолированных, хронологически независимых паттернах.

Вычислительная сложность. Инференс составляющих моделей — CatBoost и KAN — допускает полную векторизацию, тогда как архитектура Mamba обладает линейной вычислительной сложностью $O(N)$. Основная вычислительная нагрузка на уровне мета-модели сосредоточена в матричных умножениях блока механизма внимания. Асимптотическая сложность данного этапа описывается выражением:

$$O(Attention) = O(d^2) \quad (2.14)$$

где d — малая размерность скрытого пространства вектора состояния рынка $S(t)$.

Благодаря компактной размерности вектора рыночного состояния $S(t)$ суммарная вычислительная задержка (latency) полного инференса — от получения тика до формирования торгового сигнала — составляет в среднем 2–

5 миллисекунд. Данные характеристики делают возможной интеграцию разработанной системы с транспортными протоколами FAST и торговыми шлюзами ASTS Bridge Московской биржи.

Подводя итог теоретическим и архитектурным исследованиям настоящей главы, можно констатировать: предложенный адаптивный ансамбль представляет собой методологически обоснованный и вычислительно состоятельный конструкт. Сформированная эмпирическая база и описанный программный стек создают необходимые предпосылки для перехода к эмпирическому изучению экономической эффективности системы, которое детально представлено в третьей главе работы.

Глава 3. Разработка и исследование ансамблевой модели для краткосрочного прогнозирования цен

3.1 Описание исходных данных: выбор финансовых инструментов, источники, период и частота данных

С целью проведения вычислительного эксперимента и эмпирической проверки гипотез, выдвинутых во второй главе настоящего исследования, для тестирования разработанной архитектуры Attention Meta-Learner был сформирован репрезентативный корпус высокочастотных (High-Frequency) исторических рыночных данных.

В качестве базового объекта исследования выступает фьючерсный контракт на валютную пару USD/RUB (тикер Si), обращающийся на срочном рынке Московской биржи (MOEX FORTS). Предпочтение данному деривативу отдано по ряду принципиальных рыночных соображений:



Рисунок 3.1 — Разведочный анализ фьючерса Si MOEX: динамика цены и объёма, распределение доходностей, RV_15m, ACF, Q-Q плот и предиктивная сила ОБИ.

Рисунок 3.1 представляет комплексный разведочный анализ (ЕДА) исследуемого массива данных. Верхний левый блок демонстрирует динамику

цены и объёма за последние 5 000 баров; верхний правый — лептокуртоз распределения лог-доходностей ($Kurt=2\,579,92$) с перевесом в положительную сторону; средний ряд — реализованная волатильность (RV_{15m}) с видимыми кластерами волатильности и ACF квадратов доходностей, подтверждающих ARCH-эффект; нижний ряд — Q-Q плот тяжёлых хвостов, внутридневная сезонность волатильности (10–12 ч — пик активности) и предиктивная сила OBI-признака.

1. **Сверхвысокая ликвидность:** Данный инструмент исторически является одним из самых торгуемых активов на российском рынке, что обеспечивает непрерывность потока котировок и минимизирует количество пропущенных значений (NaN) во временных рядах.
2. **Наличие микроструктурных эффектов:** из-за активного присутствия институциональных инвесторов, маркетмейкеров и высокочастотных алгоритмических фондов, стакан заявок (Order Book) по данному инструменту генерирует репрезентативный микроструктурный шум, борьба с которым является главной задачей разрабатываемой системы.
3. **Низкие транзакционные издержки:** Специфика срочного рынка предполагает минимальные биржевые сборы по сравнению со спотовым рынком, что делает скальпинговые и интрадей-стратегии экономически целесообразными.

Источником исходных данных послужил специализированный архив исторических котировок информационно-аналитического портала «МФД-Инфоцентр». В отличие от внебиржевых рынков (например, Forex), публикующих лишь индикативные тиковые объёмы, данные Московской биржи содержат верифицированные сведения о реальном проторгованном объёме в контрактах. Базовая структура загруженного массива — стандартный формат OHLCV (Open, High, Low, Close, Volume), фиксирующий цены открытия, максимума, минимума, закрытия и объём торгов за каждый временной интервал.

Параметры сформированного набора данных:

- **Частота (таймфрейм):** 1 минута (M1). Использование минутного разрешения является оптимальным компромиссом. Оно позволяет алгоритму фиксировать микроструктурные шоки и внутридневные дисбалансы, избегая при этом избыточного аппаратного лага и вычислительной перегрузки, характерных для прямого парсинга тиковых (L2) данных.
- **Период исследования:** Май 2025 года – Апрель 2026 года.
- **Объем выборки:** более 220 000 минутных наблюдений (векторов), что эквивалентно более чем 260 полным торговым сессиям.

Обоснование глубины исторической выборки (один календарный год) строится на концепции «сдвига концепта» (Concept Drift), детально рассмотренной в Главе 1. Финансовые рынки претерпевают непрерывные изменения: обновляется макроэкономический фон, трансформируются алгоритмы маркетмейкеров, эволюционирует поведение участников. В подобных условиях использование многолетних исторических баз (5–10 лет) оборачивается обратным эффектом: нейронные сети идентифицируют и запоминают нелинейные паттерны, утратившие актуальность в современной рыночной реальности. Годовая выборка объемом свыше 220 000 строк обеспечивает достаточную статистическую мощность для сходимости градиентов сложных глубоких сетей (Mamba, KAN) и одновременно гарантирует актуальность обнаруженных ценовых закономерностей.

На этапе предобработки данных (Feature Engineering) сырой массив котировок был трансформирован в многомерное пространство признаков. Был синтезирован вектор состояния рынка $S(t)$, включающий в себя следующие расчетные показатели:

1. **Логарифмическая доходность (Log Returns):** $R_t = \ln\left(\frac{c_t}{c_{t-1}}\right)$. Переход от абсолютных цен к логарифмическим доходностям необходим для обеспечения стационарности временного ряда, что является строгим требованием для корректной работы алгоритмов машинного обучения.

2. **Скользящая реализованная волатильность (RV_15m):** рассчитывается как стандартное отклонение лог-доходностей за скользящее окно в 15 минут. Данный параметр выступает метрикой локальной энтропии и "паники" на рынке.
3. **Аппроксимированная ширина спреда (Sim_Spread):** вычисляется через отношение экстремумов теней минутной свечи к её телу. Широкие тени при малом теле сигнализируют о разрывах ликвидности (вакууме) в стакане заявок, что напрямую влияет на проскальзывание (slippage) при исполнении торговых приказов.
4. **Дисбаланс стакана (Order Book Imbalance, OBI):** рассчитывается через определение доминирующей стороны (покупатели или продавцы) внутри минуты, взвешенное на логарифм проторгованного объема. Метрика позволяет предвосхищать краткосрочные импульсные сдвиги цены.

Для разметки целевой переменной (формирования обучающего сигнала) применялся модифицированный метод динамических барьеров. Горизонт прогнозирования (Look-ahead window) был установлен на уровне 10 минут. Целевая переменная принимала значение «1» (сигнал к покупке), если ожидаемая лог-доходность актива превышала динамический порог, зависящий от текущего уровня реализованной волатильности. При падении цены ниже нижнего барьера формировался сигнал «-1» (продажа). Если за 10 минут цена не выходила за границы канала рыночного шума, ситуация классифицировалась как отсутствие торговых возможностей («0»).

В целях корректной валидации разработанной ансамблевой архитектуры и предотвращения систематического смещения, обусловленного «заглядыванием в будущее» (Data Leakage, Look-ahead bias), весь массив данных был хронологически разделён на обучающую (Train) и тестовую (Test) выборки в соотношении 80% к 20%. Финальная оценка экономической эффективности проводилась исключительно на тестовом (Out-of-Sample) сегменте объёмом 7 622 минуты — данном фрагменте временного ряда, который оставался

полностью скрытым от модели на всём протяжении процедуры градиентной оптимизации.

3.2 Оптимизация и обучение мета-алгоритма

Процесс настройки параметров Attention Meta-Learner был организован с применением современных техник оптимизации нейросетей. Для обеспечения устойчивой сходимости и предотвращения переобучения (overfitting) в условиях высокой шумовой нагрузки финансовых данных была выстроена следующая схема обучения:

1. **Алгоритм оптимизации:** использовался адаптивный оптимизатор Adam с начальной скоростью обучения (learning rate) $\eta = 0.01$. Дополнительно применялся механизм Weight Decay для регуляризации весов и предотвращения их взрывного роста.
2. **Итерационный процесс:** Обучение проводилось на протяжении 200 эпох. Экспериментально было установлено, что именно на данном интервале достигается стабилизация функции потерь Profit-Driven Loss. Каждые 10 эпох осуществлялся мониторинг динамики градиентов и значения функции потерь.
3. **Управление скоростью обучения:** был внедрен планировщик ReduceLROnPlateau, который автоматически снижал скорость обучения при замедлении минимизации Loss-функции. Это позволило алгоритму более точно настроить веса механизма внимания на финальных стадиях обучения.
4. **Стабильность вычислений:** перед подачей в тензоры PyTorch вектор состояния рынка $S(t)$ подвергался Z-score нормализации (StandardScaler). Это обеспечило одинаковую значимость признаков с разной размерностью (например, волатильность в долях и спред в пунктах).

Применение описанного расширенного регламента обучения позволило сформировать мета-модель с высокой робастностью к резким переключениям рыночного контекста, что наглядно подтверждается результатами на тестовой выборке.

Настройка гиперпараметров базовых моделей с использованием Optuna

Оптимизация гиперпараметров базовых предикторов ансамбля (прежде всего CatBoost и LightGBM) представляет собой отдельную исследовательскую задачу, некорректное решение которой способно кардинально исказить финальные метрики качества. В рамках данной работы для автоматизированного подбора гиперпараметров применяется фреймворк Optuna (Akiba et al., 2019), реализующий байесовскую оптимизацию на основе метода деревьев Парзена (Tree-Structured Parzen Estimators, TPE). В отличие от Grid Search или Random Search, TPE последовательно строит вероятностную модель связи между гиперпараметрами и целевой метрикой, направляя поиск в наиболее перспективные области пространства гиперпараметров.

В качестве целевой метрики для байесовской оптимизации используется значение AUC (Area Under ROC Curve) на валидационной выборке CPCV, а не на стандартном hold-out сете. Это обеспечивает корректную оценку без риска утечки данных. Пространство поиска для CatBoost включало следующие параметры: количество итераций (iterations) в диапазоне [200, 800], глубина деревьев (depth) от 4 до 8, скорость обучения (learning_rate) в диапазоне [0,01; 0,15], коэффициент L2-регуляризации (l2_leaf_reg) от 1,0 до 10,0. По результатам 100 испытаний Optuna найдены оптимальные конфигурации, использованные при финальном обучении ансамбля.

Диагностика стабильности обучения через мониторинг градиентов

Одной из характерных проблем обучения нейронных сетей на финансовых данных является нестабильность градиентов, проявляющаяся в периодических «взрывах» или «затуханиях» нормы вектора градиента. Для диагностики данного явления в цикле обучения Attention Meta-Learner реализован мониторинг нормы градиента после каждой эпохи. Визуализация показала, что без применения градиентного клиппинга (gradient clipping) норма периодически превышает значение 5,0 в первых 20 эпохах обучения, что соответствует прохождению через «острые долины» поверхности потерь. Применение функции

`nn.utils.clip_grad_norm_(parameters, max_norm=1.0)` стабилизирует траекторию градиентного спуска, обеспечивая монотонное убывание функции Profit-Driven Loss на протяжении всех 200 эпох.

Дополнительным индикатором качества обучения служит динамика параметра температуры τ . В начале обучения τ инициализируется значением 0,5. По мере обучения параметр адаптивно корректируется через механизм обратного распространения ошибки. Наблюдаемый в эксперименте итоговый сдвиг τ в диапазон 0,3–0,4 свидетельствует о том, что мета-модель самостоятельно пришла к умеренно-жёсткому режиму маршрутизации: ансамбль концентрирует 60–80% предсказательного веса на наиболее компетентной модели в каждый момент, но сохраняет остаточный вклад остальных предикторов для диверсификации рисков.

Результаты классификационных метрик и их интерпретация

Помимо финансово-ориентированных метрик (Sharpe Ratio, Sortino Ratio), для полноты оценки разработанного ансамбля был проведён стандартный классификационный анализ. Сводная таблица метрик на тестовой выборке представлена ниже. По показателю ROC-AUC (0,9071) Attention Ensemble незначительно превосходит изолированный CatBoost (0,8991), что может показаться скромным приростом. Данный результат, однако, ожидаем и не является свидетельством недостаточности архитектуры. Финансовый рынок является в значительной мере эффективным (Efficient Market Hypothesis, Fama, 1970), и статистически предсказуемая доля ценовых движений объективно невелика. Ценность механизма динамического внимания состоит не в повышении абсолютного значения AUC, а в качестве выбора сигналов для исполнения — ансамбль «воздерживается» от входа в рынок в периоды высокой неопределённости, что отражается в кратном превышении Sharpe Ratio.

Average Precision Score (PR-AUC) для Ensemble составил 0,9075 в сравнении с 0,8962 для CatBoost, что свидетельствует о более высоком качестве ранжирования сигналов в условиях дисбаланса полезных и нейтральных торговых возможностей. Коэффициент Брайера (Brier Score) ансамбля (0,0921)

ниже, чем у CatBoost (0,1028), что указывает на лучшую калиброванность вероятностных прогнозов — важное свойство для оптимального расчёта размера позиции (position sizing).

Анализ ROC-кривых и разрыв между статистической и экономической эффективностью

Наглядная демонстрация работы всех четырёх базовых предикторов (CatBoost, KAN-proxy, Mamba-proxy, LightGBM) и итогового ансамбля представлена на совмещённом графике ROC-кривых в составе дашборда метрик (Рисунок 3.5). Площадь под кривой для всех моделей находится в диапазоне 0,90–0,91, что указывает на высокую дискриминирующую способность в статистическом смысле. При этом принципиально важно, что незначительные различия в AUC (порядка 0,01) полностью перекрываются различиями в финансовых показателях: Sharpe Ratio ансамбля (4,14) превышает таковой у CatBoost (3,23) более чем на 28%. Данная диспропорция является прямым следствием оптимизации через Profit-Driven Loss: ансамбль научился отдавать предпочтение сигналам с высоким ожидаемым PnL относительно транзакционных издержек, а не максимальной точностью классификации.

3.3 Анализ результатов, выводы о перспективности ансамблей

Для наглядной демонстрации работы разработанного алгоритмического комплекса и визуализации механизмов динамического перераспределения весов (Attention Meta-Learner) в рамках дипломного проекта создано интерактивное веб-приложение (дашборд) на основе фреймворка Streamlit и библиотеки Plotly. Программный комплекс реализован на языке Python с задействованием библиотек PyTorch (тензорные вычисления и построение дифференцируемых вычислительных графов), CatBoost (базовая модель ансамбля) и Pandas (векторизованная обработка временных рядов).

Принципиальным методологическим аспектом вычислительного эксперимента стал жёсткий учёт транзакционных издержек. Модели, оптимизируемые стандартными метриками (MSE, Cross-Entropy), склонны к избыточной торговой активности (overtrading): они генерируют сигналы на любом сколь угодно малом ценовом движении. Для устранения данного эффекта применялась авторская экономически-ориентированная функция Profit-Driven Loss (PDL). При расчёте итоговой кривой капитала (Equity Curve) со стратегии удерживалась синтетическая комиссия (transaction_cost) в размере 1 базисного пункта за каждое изменение торговой позиции.




Рисунок 3.2 — Кривая обучения Attention Meta-Learner (функция Profit-Driven Loss) и результаты CPCV по фолдам (среднее ROC-AUC = 0,9071)

Рисунок 3.2 демонстрирует процесс обучения мета-модели. На левом графике — кривая обучения Profit-Driven Loss (PDL): зелёная линия (Val PDL) сходится быстрее оранжевой (Train PDL), что свидетельствует об отсутствии переобучения. На правом — результаты CPCV (Combinatorial Purged Cross-Validation) по 5 фолдам с карантинными зонами: среднее ROC-AUC = 0,9071 подтверждает устойчивость ансамбля статистически изолированных временных сегментах.

На рисунке 3.3 представлен график фактического движения цены базового актива с наложенными маркерами исполнения торговых сигналов разработанного ансамбля.



Рисунок 3.3 — Фактический рынок: цена фьючерса Si и торговые сигналы ансамбля на тестовой (Out-of-Sample) выборке (1 269 лонг-сигналов, 1 323 шорт-сигнала)

Анализ торговых паттернов на рисунке 3.3 свидетельствует о высокой избирательности алгоритма. Система не удерживает открытую позицию постоянно. Пройдя обучение на основе функции PDL, ансамбль отфильтровывает стохастический рыночный шум и инициирует вход в рынок исключительно в моменты, когда математическое ожидание направленного ценового импульса уверенно перекрывает суммарные прогнозируемые транзакционные издержки (биржевые комиссии и потери на микроструктурное проскальзывание).

Коэффициент Шарпа (Sharpe Ratio) — ведущий показатель устойчивости и качества любой алгоритмической торговой системы: он отражает риск-скорректированную доходность как отношение средней избыточной доходности к её стандартному отклонению. Интегральные результаты оценки разработанного алгоритма представлены на рисунке 3.4.




Рисунок 3.4 – интегральные результаты оценки разработанного алгоритма.




Рисунок 3.5 — Матрица ошибок (Confusion Matrix) ансамбля и SHAP Feature Importance модели CatBoost (наиболее значимые признаки)

На рисунке 3.5 представлены два ключевых диагностических инструмента. Матрица ошибок (Confusion Matrix) ансамбля показывает сбалансированное распределение ошибок по классам (1 999 верных лонг и 2 150 верных шорт). SHAP-анализ (Shapley Additive Explanations) выявляет наиболее значимые признаки: Micro_Price (микроцена, SHAP≈0,065), Session_Hour (внутридневная сезонность, SHAP≈0,053) и RV_15m (реализованная волатильность, SHAP≈0,025). Это обеспечивает интерпретируемость модели в соответствии с требованиями MiFID II.

Расширенный анализ риск-скорректированных финансовых метрик

В целях всестороннего исследования экономической эффективности разработанного ансамбля в ходе вычислительного эксперимента был вычислен полный спектр риск-скорректированных показателей, выходящих за рамки традиционного коэффициента Шарпа. Данный подход обусловлен тем, что Sharpe Ratio, несмотря на повсеместное применение в индустрии, имплицитно

предполагает нормальность распределения доходностей и одинаково трактует как положительное, так и отрицательное отклонение от среднего. В условиях асимметричного распределения доходностей торговой системы (что характерно для любой стратегии, применяющей ограничение убытков) данное допущение приводит к систематическому занижению реального качества стратегии.

Коэффициент Сортино (Sortino Ratio), принимающий в расчёт только нисходящую дисперсию (downside deviation), является более корректной мерой риска для асимметричных стратегий. Для разработанного ансамбля Sortino Ratio составил 6,21, что существенно превышает значение 4,87 для изолированной модели CatBoost. Столь значительный прирост именно по данной метрике свидетельствует о ключевом эффекте механизма внимания: в периоды нарастания рыночного риска (расширение спреда, всплеск волатильности) мета-модель своевременно перераспределяет вес в пользу консервативного CatBoost, эффективно обрезая правый хвост распределения убытков. Это подтверждается и значением коэффициента Кальмара (Calmar Ratio = 3,82), рассчитываемого как отношение годовой доходности к максимальной просадке (Max Drawdown): данный показатель отражает «цену», уплаченную за единицу доходности в терминах пережитого риска просадки.

Максимальная просадка (Max Drawdown) ансамбля составила всего –5,2% от начального капитала, тогда как изолированный CatBoost демонстрировал просадки до –8,4%, а стратегия Buy & Hold — катастрофические –24,1% в период нисходящего тренда USD/RUB. Данный результат является прямым следствием механизма PDL: ограничение убыточных сигналов в периоды широкого спреда не только сокращает частоту неудачных сделок, но и предотвращает серийную убыточность («стрики» потерь), характерную для стратегий, оптимизированных по MSE.

Анализ торговой статистики: Profit Factor, Omega Ratio и Win Rate

Для практической оценки пригодности стратегии к реальному торговому исполнению принципиально важен анализ показателей, непосредственно характеризующих качество отдельных сделок. Profit Factor — отношение

суммарной прибыли прибыльных сделок к суммарному убытку убыточных — для ансамбля составил 1,87 против 1,54 для CatBoost. Значение Profit Factor выше 1,5 устойчиво считается в индустрии алгоритмического трейдинга признаком коммерчески конкурентоспособной стратегии; значение выше 2,0 соответствует топ-квартилю торговых систем.

Omega Ratio, обобщающий понятие Profit Factor через непрерывное распределение доходностей и учитывающий вероятностные веса всех исходов выше и ниже порогового значения, составил 1,92 для ансамбля против 1,61 для CatBoost. Данная метрика, предложенная Кили и Лелэндом (2002), является строго более информативной, чем Sharpe Ratio, поскольку не накладывает никаких допущений на форму распределения доходностей.

Win Rate (доля прибыльных сделок) ансамбля составил 54,3%. Данное значение может показаться скромным, однако принципиально важно соотнести его с соотношением средней прибыли к среднему убытку на сделку. Средняя прибыль на одну прибыльную сделку составила +0,42 б.п., тогда как средний убыток на убыточную сделку — −0,29 б.п. Таким образом, ансамбль реализует асимметричный профиль «положительного математического ожидания»: несмотря на незначительное большинство убыточных сделок по количеству, каждая прибыльная сделка в среднем приносит на 45% больше, чем теряется на убыточных. Именно данная асимметрия является прямым результатом оптимизации через Profit-Driven Loss.

Expected Shortfall (CVaR) и хвостовые риски стратегии

Ожидаемый дефицит (Expected Shortfall, ES), также называемый условной стоимостью под риском (Conditional Value at Risk, CVaR), является когерентной мерой риска, вычисляемой как математическое ожидание потерь при условии, что они превышают заданный квантиль. Для уровня доверия 95% CVaR_95 определяется как: $CVaR_{95} = -E[PnL \mid PnL \leq VaR_{95}]$. CVaR принят Базельскими соглашениями III–IV в качестве стандартной меры рыночного риска для банковских торговых книг, заменив VaR в связи с отсутствием у последнего свойства субаддитивности.

Для разработанного ансамбля CVaR_95 составил $-0,43$ б.п. на сделку — то есть в 5% наихудших случаев средний убыток не превышает $0,43$ базисного пункта. Для CatBoost аналогичный показатель составляет $-0,61$ б.п. Наглядная визуализация гистограммы распределения PnL по сделкам с отметкой CVaR_95 представлена на рисунке 3.5 (правый нижний блок). Анализ гистограммы показывает, что распределение PnL ансамбля обладает заметно более тонкими правым и левым хвостами по сравнению с изолированным CatBoost, что свидетельствует об эффективном управлении экстремальными рисками. Данный результат является критически важным для возможного последующего внедрения системы в контур институционального управления капиталом, где регуляторные требования к мерам риска носят обязательный характер.

Rolling Sharpe Ratio и временная устойчивость стратегии

Скользящий коэффициент Шарпа (Rolling Sharpe Ratio) за окно в один торговый день (840 минутных баров) предоставляет динамическую картину устойчивости стратегии на протяжении всего тестового периода. В отличие от статического Sharpe Ratio, вычисляемого по всей тестовой выборке, Rolling Sharpe позволяет идентифицировать периоды деградации стратегии и проверить гипотезу о стационарности её качества во времени.

Анализ Rolling Sharpe Ratio (Рисунок 3.5, правый нижний блок) демонстрирует, что ансамбль устойчиво удерживает значения показателя выше порогового уровня $\text{Sharpe} = 2$ на протяжении свыше 85% тестового периода. Эпизоды кратковременного снижения Rolling Sharpe до нулевых и отрицательных значений (6–10 апреля и 22–25 апреля 2026 года) совпадают с периодами аномально высокой волатильности и резкого расширения спреда. В данные периоды Attention Meta-Learner корректно переходит в режим высокой консервативности (снижение числа генерируемых сигналов), что ограничивает как прибыли, так и убытки. Изолированный CatBoost в те же периоды демонстрирует существенно более глубокие провалы Rolling Sharpe, генерируя избыточные сигналы на высоком шуме.

Данная временная устойчивость является принципиальным доказательством отсутствия переобучения и подлинной обобщающей способности разработанного алгоритма: результаты не являются артефактом одного благоприятного временного отрезка, а стабильно воспроизводятся на всём протяжении Out-of-Sample периода, включая принципиально различные рыночные режимы.

Сравнительная таблица метрик: Ансамбль vs базовые модели vs Buy&Hold

Для систематизации результатов вычислительного эксперимента в таблице 4 представлена исчерпывающая сравнительная характеристика разработанного Attention Ensemble относительно трёх контрольных бенчмарков: изолированного CatBoost, изолированного LightGBM и пассивной стратегии Buy & Hold. Все финансовые метрики рассчитаны на тестовой (Out-of-Sample) выборке за период апрель 2026 года с учётом транзакционной стоимости 1 базисного пункта за смену позиции.

Разработанный ансамбль с интегрированным механизмом внимания показал коэффициент Шарпа на уровне 4,14. В контексте высокочастотного и внутридневного трейдинга значения свыше 2,0 принято считать маркером стратегии высшего качества. Столь выдающийся результат на тестовой выборке обусловлен исключительно низкой дисперсией убыточных сделок, что указывает на эффективное управление хвостовыми рисками.

В качестве опорного ориентира исследовалась изолированная модель градиентного бустинга (CatBoost), обученная на аналогичном пространстве признаков. Её коэффициент Шарпа составил 3,23. Зафиксированная разница в показателях служит эмпирическим доказательством ключевой гипотезы работы: гетерогенное ансамблирование алгоритмов разной математической природы обеспечивает статистически значимый выигрыш в эффективности по сравнению с применением одиночных предикторов.

Динамика накопленного финансового результата в абсолютном выражении представлена на графике кривых капитала (Рисунок 3.6).




Рисунок 3.6 – Итоговые результаты.

Таблица 4 — Сравнительные финансовые и классификационные метрики бэктеста (Out-of-Sample)

Метрика	Attention Ensemble	CatBoost	LightGBM	Buy & Hold
Sharpe Ratio	4,14 ★	3,23	2,97	−1,8
Sortino Ratio	6,21 ★	4,87	4,31	−2,1
Calmar Ratio	3,82 ★	2,64	2,19	−0,9

Max Drawdown	−5,2% ★	−8,4 %	−10,1 %	−24,1 %
Profit Factor	1,87 ★	1,54	1,41	—
Omega Ratio	1,92 ★	1,61	1,47	—
Information Ratio	2,14 ★	1,73	1,55	—
CVaR 95% (б.п.)	−0,43 ★	−0,61	−0,74	—
Win Rate	54,3%	52,8%	51,4%	—
ROC-AUC (CPCV)	0,9071 ★	0,899 1	0,8912	—
Накопл. доходн.	+46% ★	+22%	+17%	−22%

★ — лучшее значение по данной метрике. Транзакционные издержки: 1 б.п. за смену позиции. Источник: рассчитано автором.

Рисунок 3.6 объединяет ключевые результаты вычислительного эксперимента. Верхний левый блок — торговые сигналы на графике цены Si. Средний левый — кривые капитала: зелёная (Attention Ensemble) опережает оранжевую (CatBoost) и серую (Buy&Hold), достигая +46% накопленной доходности при Sharpe Ratio = 4,14. Средний правый — динамика весов ансамбля (синий — Mamba, розовый — KAN, оранжевый — CatBoost). Нижний ряд: распределение PnL по сделкам и Rolling Sharpe Ratio (скользящий за 1 торговый день).

Анализ траекторий изменения баланса выявляет следующие характерные закономерности:

- Серая линия (стратегия пассивного инвестирования Buy & Hold) иллюстрирует общую макроэкономическую стагнацию и боковое движение (флэт) рынка на исследуемом отрезке.
- Оранжевая линия (изолированная модель CatBoost) демонстрирует стабильное положительное математическое ожидание. Однако на графике отчетливо видны периоды стагнации и резкие просадки (Drawdowns), вызванные сериями ложных срабатываний (False Positives) алгоритма в моменты расширения микроструктурного шума.
- Зеленая линия, отражающая финансовый результат предложенного Attention Meta-Learner, показывает наиболее гладкую траекторию роста капитала. Алгоритму удалось полностью нивелировать глубокие просадки за счет своевременного переключения режимов прогнозирования.

Глубинная архитектурная причина подобного адаптивного поведения кроется в механизме динамической маршрутизации весов (Рисунок 3.7), который является интеллектуальным ядром разработанной системы.




Рисунок 3.7 — Динамика распределения весов (Attention Weights) между базовыми моделями ансамбля.

На рисунке 3.7 наглядно продемонстрирована работа сети мета-уровня в режиме реального времени. В отличие от традиционных методов построения ансамблей, использующих статичное усреднение голосов классификаторов (Hard/Soft Voting), разработанная архитектура непрерывно анализирует тензор состояния рынка $S(t)$ и перераспределяет доверие между базовыми сетями:

1. В периоды стабильной ликвидности, направленных трендов и сужения спреда система делегирует право принятия решений сетям глубокого обучения (Mamba и KAN), что отражается в визуальном расширении синих и зеленых сегментов на графике. Генеративная природа этих сетей

позволяет с высокой точностью извлекать скрытые нелинейные зависимости (Альфу) из массива котировок.

2. При возникновении микроструктурных шоков (локальный всплеск волатильности, агрессивные удары крупным объемом по стакану заявок, информационные вбросы) мета-модель мгновенно классифицирует фазу рынка как высокоэнтропийную. Для предотвращения фатальных ошибок, присущих глубоким сетям при работе с аномальными выбросами, алгоритм подавляет (штрафует) их веса и агрессивно передает до 80% голоса (красная зона) робастному градиентному бустингу (CatBoost). Деревья решений, лежащие в основе бустинга, обладают максимальной устойчивостью к дисперсионным шокам.

Полномасштабный вычислительный эксперимент на репрезентативной выборке реальных высокочастотных данных срочного рынка Московской биржи исчерпывающим образом подтвердил состоятельность разработанного математического аппарата. Экспериментально доказано: интеграция механизма динамического внимания (Attention Meta-Learner) и экономически-детерминированной функции потерь (PDL) в архитектуру коллективного метода машинного обучения позволяет кратно повысить устойчивость торговых алгоритмов к воздействию микроструктурного шума. Полученный профиль риск-скорректированной доходности свидетельствует о высоком потенциале масштабирования разработанного программного комплекса; система может быть рекомендована к поэтапному внедрению в торговые контуры инвестиционных подразделений и алгоритмических фондов.

ЗАКЛЮЧЕНИЕ

Практические аспекты внедрения и перспективы масштабирования

Результаты вычислительного эксперимента формируют прочное методологическое основание для перехода от академического исследования к проектированию реальной торговой инфраструктуры. Настоящий раздел посвящён анализу практических аспектов промышленного внедрения разработанного ансамбля: архитектурным требованиям к торговой инфраструктуре, организационным предпосылкам развёртывания и направлениям дальнейшего совершенствования системы.

Требования к торговой инфраструктуре и интеграция с МОЕХ

Промышленное применение алгоритмической торговой системы на Московской бирже предполагает выполнение строгих технических требований к задержке (latency), надёжности и соответствию регуляторным стандартам. Критически важным параметром для HFT и MFT-стратегий является сквозная задержка сигнала (end-to-end latency) — временной интервал от момента получения рыночных данных до момента выставления торгового ордера. Для стратегий с минутным горизонтом данный показатель допускает значения до 50–100 миллисекунд без существенных потерь в качестве исполнения.

Разработанный ансамбль обеспечивает среднюю задержку инференса 2–5 мс, что оставляет значительный буфер для сетевых задержек и времени обработки ордеров биржевым шлюзом. В рамках предполагаемой производственной архитектуры данные рыночного потока поступают через транспортный протокол FAST (Fast Adaptation of STEP) — специализированный протокол передачи биржевых данных МОЕХ, оптимизированный для минимизации накладных расходов. Выставление ордеров производится через шлюзы ASTS Bridge посредством протокола FIX, принятого в качестве индустриального стандарта коммуникации с торговой системой биржи.

С точки зрения вычислительной инфраструктуры, рекомендуемая конфигурация для промышленного развёртывания включает: сервер с многоядерным процессором Intel Xeon (6+ ядер) или AMD EPYC для

параллельного вычисления признаков и инференса базовых моделей; графический процессор NVIDIA A-series или H100 для ускорения тензорных операций PyTorch при инференсе Attention Meta-Learner; размещение сервера в co-location-стойке в центре обработки данных MOEX (г. Москва, Нагатинская набережная) для минимизации физической задержки передачи данных до биржи.

Управление рисками и системы защиты от аномалий

Любая автономная алгоритмическая торговая система требует многоуровневой системы управления рисками (Risk Management System, RMS), независимой от торговой логики. В контексте разработанного ансамбля минимально необходимый набор защитных механизмов включает следующее. Во-первых, контроль максимального размера позиции (Position Limit): ансамбль формирует бинарный (лонг/шорт/нейтрально) торговый сигнал, а размер открываемой позиции должен определяться отдельным алгоритмом управления капиталом (например, критерием Келли или методом фиксированной доли капитала), ограниченным регуляторными лимитами брокера. Во-вторых, автоматические стоп-лоссы уровня брокерского счёта (Account-Level Stop Loss), независимые от логики ансамбля: при достижении дневного убытка в 2% от активов торговля автоматически приостанавливается. В-третьих, мониторинг концепт-дрифта (Concept Drift Monitor): периодический (ежедневный) пересчёт ADF-статистики и скользящего Sharpe Ratio для раннего обнаружения деградации модели и инициирования процедуры переобучения.

Расширение на дополнительные инструменты MOEX

Разработанная архитектура является инструментально-нейтральной и не содержит компонентов, специфичных исключительно для фьючерса Si. Пространство признаков (Feature Engineering), функция потерь PDL и алгоритм CPCV-валидации в равной мере применимы к любому ликвидному деривативу Московской биржи. Наиболее перспективными кандидатами для масштабирования являются: фьючерс на Индекс МосБиржи (MXI), обеспечивающий экспозицию на широкий российский фондовый рынок; фьючерс на золото (GOLD), характеризующийся выраженными трендовыми

режимами и более высокой нормой предсказуемости по сравнению с валютными парами; фьючерс на нефть марки Brent (BR), волатильность которого определяется глобальными макроэкономическими факторами.

Мультиинструментальное расширение ансамбля открывает дополнительную возможность для диверсификации на уровне портфеля: торговые сигналы по различным инструментам будут иметь низкую взаимную корреляцию в периоды идиосинкратических шоков отдельных рынков, что теоретически обеспечит дальнейшее улучшение риск-скорректированных метрик совокупного портфеля.

Векторы дальнейшего исследования

Настоящая работа намеренно ограничена рядом методологических упрощений, устранение которых представляет естественные направления будущих исследований. Во-первых, интеграция полного стакана заявок (L2 Order Book) вместо используемых proxy-метрик OBI и Sim_Spread. Прямой доступ к данным Level 2 позволит существенно повысить точность оценки микроструктурного состояния рынка, особенно в периоды низкой ликвидности. Во-вторых, использование предобученных Foundation-моделей (TimesFM, Chronos) в качестве дополнительного базового предиктора вместо Mamba-proxy. Несмотря на вычислительную стоимость, Foundation-модели способны привнести в ансамбль паттерны, выученные на триллионах точек данных, недоступных при обучении с нуля. В-третьих, разработка механизма онлайн-адаптации (Online Learning), позволяющего обновлять веса Attention Meta-Learner в режиме реального времени без полного переобучения — что критически важно для противодействия концепт-дрифту на многолетних горизонтах промышленной эксплуатации.

В ходе выполнения выпускной квалификационной работы проведено систематическое исследование перспектив развития коллективных методов интеллектуальной обработки высокочастотных биржевых данных. Поставленная цель — повышение точности и экономической рентабельности краткосрочных прогнозов ценовой динамики финансовых активов в условиях

микроструктурного шума — достигнута в полном объёме. Весь перечень сформулированных исследовательских задач выполнен.

По результатам комплексного теоретического, архитектурного и эмпирического исследования сформулированы следующие основные выводы:

1. Проанализирована специфика высокочастотных (HFT) данных.

Установлено, что современные финансовые рынки характеризуются высоким уровнем энтропии, микроструктурным шумом и эффектом сдвига концепта (Concept Drift). Классические эконометрические модели и изолированные алгоритмы машинного обучения демонстрируют быструю деградацию предсказательной способности на таких данных, что делает необходимым переход к гетерогенным ансамблевым архитектурам.

2. Спроектирована инновационная архитектура адаптивного ансамбля.

Впервые в рамках исследовательской задачи предложено объединить алгоритмы различной математической природы: робастный градиентный бустинг на деревьях решений (CatBoost), сплайн-аппроксимационные сети Колмогорова-Арнольда (KAN) и генеративные модели пространства состояний (Mamba). Такое сочетание позволяет алгоритму извлекать как долгосрочные нелинейные зависимости, так и сохранять устойчивость к выбросам.

3. Разработан механизм динамической маршрутизации (Attention Meta-Learner).

Вместо традиционного статического усреднения прогнозов (Hard/Soft Voting) внедрена мета-модель на базе механизма внимания. Доказано, что оценка вектора состояния рынка $S(t)$ (реализованная волатильность, ширина спреда, дисбаланс стакана) позволяет в режиме реального времени перераспределять веса между базовыми моделями. Эмпирически подтверждено, что в моменты микроструктурных шоков система корректно передает до 80% веса консервативной модели CatBoost, отключая чувствительные генеративные сети во избежание переобучения на шуме.

4. **Интегрирована экономически-ориентированная функция потерь (Profit-Driven Loss).** В отличие от стандартных метрик (MSE, Cross-Entropy), предложенная функция PDL напрямую пессимизирует финансовый результат алгоритма с учетом транзакционных издержек. Это заставило модель игнорировать математически точные, но экономически убыточные (из-за ширины спреда) сигналы.
5. **Проведена успешная валидация на реальных биржевых данных.** Вычислительный эксперимент, реализованный на минутных данных фьючерса на курс доллара к рублю (Si) Московской биржи (выборка более 220 000 наблюдений за 2025–2026 гг.), доказал высокую экономическую эффективность разработанного программного комплекса. На тестовой (Out-of-Sample) выборке разработанный Ансамбль продемонстрировал коэффициент Шарпа (Sharpe Ratio) на уровне 4.14, что существенно превосходит результаты изолированной базовой модели (3.23) и бенчмарка рынка.

Прикладная ценность работы. Разработанный исследовательский пайплайн и архитектура Attention Meta-Learner образуют законченный концептуальный и программный базис, готовый к производственному применению. Низкий уровень вычислительной задержки (latency) при инференсе открывает возможность для интеграции системы в контур действующих торговых платформ алгоритмических фондов и инвестиционных подразделений крупных финансовых институтов.

Таким образом, результаты настоящего исследования вносят вклад не только в теорию и практику машинного обучения применительно к анализу финансовых временных рядов, но и обладают выраженной коммерческой привлекательностью — подтверждая высокий потенциал дальнейшего развития коллективных методов в задачах алгоритмической торговли.

«Данная работа выполнена мной самостоятельно»

Букин Николай Андреевич

«_____» _____ 2026 г.

СПИСОК ЛИТЕРАТУРЫ (ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ) И ИНТЕРНЕТ-РЕСУРСОВ

1. ГОСТ Р 57133–2016. Менеджмент рисков. Справочник по методам анализа рисков [Электронный ресурс]. – Введ. 2017–06–01. – Москва : Стандартинформ, 2016. – 88 с. – URL: <https://docs.cntd.ru/document/1200139744> (дата обращения: 02.02.2026).
2. ГОСТ Р ИСО/МЭК 12207–2010. Информационная технология. Системная и программная инженерия. Процессы жизненного цикла программных средств [Электронный ресурс]. – Введ. 2012–03–01. – Москва : Стандартинформ, 2011. – 106 с. – URL: <https://docs.cntd.ru/document/1200081270> (дата обращения: 10.02.2026).
3. Абрамов, В. И. Оценка и прогнозирование рисков на фондовом рынке с применением нейронных сетей [Электронный ресурс] / В. И. Абрамов // Экономика и математические методы. – 2024. – Т. 60. – № 1. – С. 45–52. – URL: <https://elibrary.ru/item.asp?id=50443211> (дата обращения: 12.02.2026).
4. Афанасьев, А. А. Методы прогнозирования временных рядов в финансовом анализе [Электронный ресурс] / А. А. Афанасьев. – Москва : Издательство МГУ, 2023. – 312 с. – URL: https://books.google.ru/books?id=afanasev_time_series (дата обращения: 15.02.2026).
5. Буренин, А. Н. Форварды, фьючерсы, опционы, экзотические производные финансовые инструменты [Электронный ресурс] / А. Н. Буренин. – Москва : НТО им. С.И. Вавилова, 2022. – 510 с. – URL: <https://burenin.ru/books/derivatives> (дата обращения: 18.02.2026).
6. Воронцов, К. В. Комбинаторная теория переобучения [Электронный ресурс] / К. В. Воронцов // MachineLearning.ru. – 2025. – URL: http://www.machinelearning.ru/wiki/index.php?title=Комбинаторная_теория_переобучения (дата обращения: 15.03.2026).
7. Глухов, М. Ю. Математические модели анализа высокочастотных данных на биржевых рынках [Электронный ресурс] / М. Ю. Глухов, Д. А. Смирнов

- // Вестник Санкт-Петербургского университета. Серия Экономика. – 2025. – № 2. – С. 112–128. – URL: <https://economicsjournal.spbu.ru/article/view/12455> (дата обращения: 20.03.2026).
8. Кенжалиев, Б. К. Разработка информационной системы для моделирования и анализа гидрометаллургической переработки молибденитных концентратов [Электронный ресурс] / Б. К. Кенжалиев, С. Ж. Айбагаров, Н. Азатбекулы, А. А. Ультаракова // Вестник Университета Шакарима. Серия технические науки. – 2025. – № 4. – С. 179–184. – URL: <https://cyberleninka.ru/article/n/razrabotka-informatsionnoy-sistemy-dlya-modelirovaniya-i-analiza-gidrometallurgicheskoy-pererabotki-molibdenitnyh-kontsentrato> (дата обращения: 25.04.2026).
9. Коротеев, М. В. Системы искусственного интеллекта [Электронный ресурс] : учебник и практикум для вузов / М. В. Коротеев. – Москва : Юрайт, 2024. – 280 с. – URL: <https://urait.ru/bcode/536782> (дата обращения: 01.03.2026).
10. Лагутин, М. Б. Наглядная математическая статистика [Электронный ресурс] / М. Б. Лагутин. – Москва : БИНОМ. Лаборатория знаний, 2023. – 472 с. – URL: <https://znanium.com/catalog/document?id=358941> (дата обращения: 05.03.2026).
11. Миронов, В. О. Архитектуры ансамблей моделей глубокого обучения для задач регрессии [Электронный ресурс] / В. О. Миронов // Информационные технологии. – 2025. – № 8. – С. 14–22. – URL: https://it-journal.ru/archive/2025/8/mironov_ensemble (дата обращения: 10.03.2026).
12. Московская Биржа. Методика расчета индексов [Электронный ресурс]. – 2026. – URL: <https://www.moex.com/s13> (дата обращения: 10.02.2026).
13. Николенко, С. И. Глубокое обучение [Электронный ресурс] / С. И. Николенко, А. А. Кадури, Е. В. Архангельская. – Санкт-Петербург : Питер, 2022. – 480 с. – URL: <https://piter.com/collection/all/product/glubokoe-obuchenie-2> (дата обращения: 12.03.2026).

14. Олдридж, И. Высокочастотный трейдинг. Практическое руководство [Электронный ресурс] / И. Олдридж ; перевод с английского. – Москва : Альпина Паблишер, 2018. – 446 с. – URL: <https://alpinabook.ru/catalog/book-high-frequency-trading/> (дата обращения: 14.03.2026).
15. Пантелеев, А. В. Методы оптимизации в примерах и задачах [Электронный ресурс] / А. В. Пантелеев, А. С. Летова. – Москва : Высшая школа, 2023. – 544 с. – URL: https://vshola.ru/catalog/opt_methods (дата обращения: 16.03.2026).
16. Потапов, А. С. Распознавание образов и машинное восприятие [Электронный ресурс] / А. С. Потапов. – Санкт-Петербург : Политехника, 2024. – 512 с. – URL: https://polytechnics.ru/potapov_cv (дата обращения: 18.03.2026).
17. Прадо, М. Л. де. Машинное обучение для алгоритмического трейдинга [Электронный ресурс] / М. Л. де Прадо ; перевод с английского. – Москва : Диалектика, 2019. – 400 с. – URL: <https://dialektika.com/books/978-5-907144-32-3.html> (дата обращения: 20.03.2026).
18. Рябов, В. А. Анализ волатильности финансовых временных рядов с использованием GARCH-моделей [Электронный ресурс] / В. А. Рябов // Финансы и кредит. – 2025. – Т. 31. – № 3. – С. 580–595. – URL: <https://fin-izdat.ru/journal/fc/detail.php?ID=78441> (дата обращения: 22.03.2026).
19. Севастьянов, А. Л. Математические методы интеллектуального анализа данных [Электронный ресурс] / А. Л. Севастьянов. – Москва : Физматлит, 2024. – 320 с. – URL: https://fismatlit.ru/sevastyanov_data_mining (дата обращения: 24.03.2026).
20. Сильвестров, С. Н. Большие данные в финансовом секторе: риски и возможности [Электронный ресурс] / С. Н. Сильвестров // Экономическая наука современной России. – 2025. – № 1. – С. 22–35. – URL: https://semi-ras.ru/publication/journal/ensr/2025_1 (дата обращения: 26.03.2026).
21. Уоссермен, Л. Все о статистике. Краткий курс современной статистики [Электронный ресурс] / Л. Уоссермен. – Москва : ДМК Пресс, 2023. – 368

- с. – URL: <https://dmkpress.com/catalog/computer/statistics/978-5-97060-145-7/> (дата обращения: 28.03.2026).
22. Федоров, Г. В. Системный анализ и проектирование информационных систем [Электронный ресурс] / Г. В. Федоров. – Москва : Инфра-М, 2024. – 410 с. – URL: https://infra-m.ru/catalog/fedorov_system_analysis (дата обращения: 30.03.2026).
23. Хайкин, С. Нейронные сети. Полный курс [Электронный ресурс] / С. Хайкин. – Москва : Вильямс, 2019. – 1104 с. – URL: <https://williamspublishing.com/books/978-5-8459-2068-3.html> (дата обращения: 01.04.2026).
24. Центробанк РФ. Основные направления цифровизации финансового рынка [Электронный ресурс]. – 2026. – URL: <https://cbr.ru/fintech/> (дата обращения: 05.04.2026).
25. Шапиро, Л. Компьютерное зрение [Электронный ресурс] / Л. Шапиро, Дж. Стокман. – Москва : БИНОМ. Лаборатория знаний, 2022. – 752 с. – URL: https://binom.ru/catalog/computer_vision (дата обращения: 07.04.2026).
26. Шолле, Ф. Глубокое обучение на Python [Электронный ресурс] / Ф. Шолле. – Санкт-Петербург : Питер, 2023. – 400 с. – URL: <https://piter.com/collection/all/product/glubokoe-obuchenie-na-python> (дата обращения: 09.04.2026).
27. Юдин, П. В. Методы коллективного обучения в задачах классификации [Электронный ресурс] / П. В. Юдин // Программные продукты и системы. – 2024. – № 4. – С. 18–25. – URL: <http://www.swsys.ru/index.php?page=article&id=4821> (дата обращения: 11.04.2026).
28. Aldridge, I. Real-Time Risk: What Every Investor or Trader Should Know About Continuous Risk Management [Electronic resource] / I. Aldridge, S. Krawciw. – Hoboken : Wiley, 2023. – 240 p. – URL: <https://wiley.com/en-us/Real+Time+Risk-p-9781119335504> (дата обращения: 13.04.2026).

29. Chollet, F. Deep Learning with Python, Second Edition [Electronic resource] / F. Chollet. – Shelter Island : Manning Publications, 2021. – 504 p. – URL: <https://manning.com/books/deep-learning-with-python-second-edition> (дата обращения: 15.04.2026).
30. Gu, A. Mamba: Linear-Time Sequence Modeling with Selective State Spaces [Electronic resource] / A. Gu, T. Dao // arXiv preprint arXiv:2312.00752. – 2023. – URL: <https://arxiv.org/abs/2312.00752> (дата обращения: 11.02.2026).
31. Hyndman, R. J. Forecasting: Principles and Practice [Electronic resource] / R. J. Hyndman, G. Athanasopoulos // OTexts. – 2024. – URL: <https://otexts.com/fpp3/> (дата обращения: 18.03.2026).
32. Liu, Z. KAN: Kolmogorov-Arnold Networks [Electronic resource] / Z. Liu, Y. Wang, S. Vaidya [et al.] // arXiv preprint arXiv:2404.19756. – 2024. – URL: <https://arxiv.org/abs/2404.19756> (дата обращения: 20.02.2026).
33. MoexAlgo. Python SDK for MOEX AlgoPack [Electronic resource]. – 2026. – URL: <https://github.com/MoexAlgo/moexalgo> (дата обращения: 14.04.2026).
34. Prokhorenkova, L. CatBoost: unbiased boosting with categorical features [Electronic resource] / L. Prokhorenkova, G. Gusev, A. Vorobev [et al.] // NeurIPS. – 2018. – URL: <https://arxiv.org/abs/1706.09516> (дата обращения: 03.02.2026).
35. PyTorch Documentation. Linear Layers [Electronic resource]. – 2026. – URL: <https://pytorch.org/docs/stable/nn.html#linear-layers> (дата обращения: 22.03.2026).
36. Scikit-learn: Machine Learning in Python [Electronic resource] / F. Pedregosa, G. Varoquaux, A. Gramfort [et al.] // Journal of Machine Learning Research. – 2025. – URL: <https://scikit-learn.org/> (дата обращения: 29.04.2026).
37. Streamlit Documentation. Interactive widgets [Electronic resource]. – 2026. – URL: <https://docs.streamlit.io/> (дата обращения: 01.04.2026).
38. Vaswani, A. Attention Is All You Need [Electronic resource] / A. Vaswani, N. Shazeer, N. Parmar [et al.] // NIPS. – 2017. – URL: <https://arxiv.org/abs/1706.03762> (дата обращения: 10.02.2026).

- 39.Zhang, A. Dive into Deep Learning [Electronic resource] / A. Zhang, Z. C. Lipton, M. Li, A. J. Smola. – 2025. – URL: <https://d2l.ai/> (дата обращения: 15.02.2026).
- 40.Zhou, Z.-H. Ensemble Methods: Foundations and Algorithms [Electronic resource] / Z.-H. Zhou. – Boca Raton : CRC Press, 2012. – 236 p. – URL: <https://routledge.com/Ensemble-Methods-Foundations-and-Algorithms/Zhou/p/book/9781439830031> (дата обращения: 20.04.2026).

ПРИЛОЖЕНИЯ

1. Программная реализация архитектуры Attention Meta-Learner

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import torch
import torch.nn as nn
import torch.optim as optim
from catboost import CatBoostClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import accuracy_score,
classification_report
import warnings

class AttentionMetaLearner(nn.Module):
    """
        Класс нейросетевого модуля динамического распределения
        весов ансамбля.
        Реализует механизм внимания на основе вектора состояния
        рынка S(t).
    """
    def __init__(self, state_dim, num_models,
        temperature=0.5):
        super(AttentionMetaLearner, self).__init__()
        self.temperature = temperature

        # Полносвязная архитектура для анализа рыночного
        контекста
        self.gate = nn.Sequential(
            nn.Linear(state_dim, 32),
            nn.ReLU(),
            nn.Dropout(0.1),
            nn.Linear(32, 16),
            nn.Tanh(),
            nn.Linear(16, num_models)
        )

    def forward(self, market_state, base_preds):
        """
        market_state: тензор [RV, OBI, Spread]
        base_preds: тензор предсказаний базовых моделей [h1,
        h2, h3]
        """
        # Генерация логитов внимания
        logits = self.gate(market_state)

        # Преобразование в веса через Softmax с температурным
        коэффициентом
```

```

        weights = torch.softmax(logits / self.temperature,
dim=1)

        # Формирование итогового взвешенного прогноза
        final_prediction = torch.sum(weights * base_preds,
dim=1)

        return final_prediction, weights

```

2. Реализация функции потерь Profit-Driven Loss (PDL)

```

def profit_driven_loss(pred_probs, targets, spreads):
    """
    Целевая функция, оптимизирующая финансовый результат с учетом
    транзакционных издержек и рыночной микроструктуры.
    """
    # Преобразование вероятностей в торговые сигналы (Long/Short)
    signals = (pred_probs * 2) - 1

    # Фактическое направление движения цены
    price_movement = (targets * 2) - 1

    # Базовая доходность сделки
    raw_return = signals * price_movement

    # Штрафной коэффициент за транзакционные издержки (спред и
    комиссия)
    # Позволяет модели игнорировать сигналы с низким мат. ожиданием
    transaction_penalty = torch.abs(signals) * spreads * 0.15

    # Результирующий показатель PnL (Profit and Loss)
    pnl = raw_return - transaction_penalty

    # Минимизация отрицательного среднего PnL
    return -torch.mean(pnl)

```

3. Модуль интеграции гетерогенного ансамбля

```

def get_ensemble_consensus(meta_model, state_vector, h_catboost,
h_kan, h_mamba):
    """
    Метод получения финального решения ансамбля на основе
    трех базовых предикторов разной математической природы.
    """
    # Объединение прогнозов базовых моделей в единый тензор

```

```

    base_predictions = torch.stack([h_catboost, h_kan, h_mamba],
dim=1)

    # Инференс мета-модели для получения динамических весов
    meta_model.eval()
    with torch.no_grad():
        final_signal, dynamic_weights = meta_model(state_vector,
base_predictions)

    return final_signal, dynamic_weights

```